Học tương phản có giám sát phân cấp ở mức token kết hợp CRF cho nhận dạng thực thể trong văn bản thủ tục hành chính tiếng Việt

Nguyễn Thị Bích Nguyên, Lê Trung Kiên, Huỳnh Tiến Đạt
Đặng Thành Tài, Nguyễn Trường Giang và Nguyễn Thành Hưng
Khoa Công nghệ Thông tin 2, Học viện Công nghệ Bưu chính Viễn thông, Việt Nam
Email tác giả liên hệ: ntbichnguyen@ptithcm.edu.vn

***Tóm tắt*—Nhận diện thực thể trong văn bản thủ tục hành chính tiếng Việt gặp hai khó khăn liên quan: thực thể dài dễ sai ranh giới và các loại ít xuất hiện cung cấp ít mẫu dương trong mỗi mini-batch. Học tương phản theo nhãn BIO chính xác còn tạo xung đột khi coi `B-X` và `I-X` của cùng loại thực thể là cặp âm. Nghiên cứu này đề xuất hàm mất mát học tương phản có giám sát phân cấp (H-SupCon): các token trùng nhãn BIO là mẫu dương mạnh, token cùng loại nhưng khác tiền tố BIO là mẫu dương mềm, còn nhãn `O` bị loại khỏi nhánh tương phản. H-SupCon được tối ưu đồng thời với log-hợp lý âm của CRF; đầu chiếu chỉ dùng khi huấn luyện nên không làm tăng đường suy luận. Trên 10.278 mẫu PAP_NER, XLM-R + CRF-H-SupCon và PhoBERT V2 + CRF-H-SupCon lần lượt đạt 97,28% và 97,92% Strict Micro F1; ELECTRA + CRF-H-SupCon đạt 98,40%, còn đối chứng PhoBERT V2 + CRF đạt 97,98%. BamiBERT + CRF-H-SupCon đạt 98,48% trên 5.162 mẫu. H-SupCon thấp hơn đối chứng PhoBERT ghép cặp 0,06 điểm; cùng với khác biệt tập kiểm thử và việc mỗi cấu hình mới có một lần chạy, kết quả chưa chứng minh tác động nhân quả của loss mới. Bài viết trình bày công thức loss, kiến trúc tối ưu chung và giao thức kiểm chứng cần thiết.**

***Từ khóa*—nhận diện thực thể, tiếng Việt, PAP_NER, CRF, học tương phản có giám sát, ranh giới thực thể.**

I. Giới thiệu

Văn bản thủ tục hành chính thường chứa tên cơ quan thực hiện, đối tượng áp dụng, thời điểm, số lượng và căn cứ pháp lý. Một hệ thống NER có thể chuyển các đoạn văn bản này thành các thực thể có ranh giới và loại xác định, phục vụ tìm kiếm, đối chiếu quy định và hỗ trợ xử lý hồ sơ. Khó khăn nổi bật là các cụm tên cơ quan hoặc trích dẫn văn bản pháp luật có thể dài, chứa ký hiệu và dễ bị tách sai ranh giới.

PAP_NER là bộ dữ liệu công khai gồm năm loại thực thể: cơ quan (CQ), đối tượng (ĐT), văn bản pháp luật (VBPL), ngày tháng (NG) và số lượng (SL) [1]. Trong tập huấn luyện địa phương, số token `I-VBPL` gấp khoảng 3,31 lần `B-VBPL`; đồng thời SL chỉ chiếm 7,15% tổng số thực thể của toàn bộ dữ liệu. Hai đặc điểm này gợi ra một khoảng trống: mục tiêu học biểu diễn cần bảo toàn quan hệ giữa phần mở đầu và phần thân của thực thể dài, nhưng vẫn phải giữ thông tin ranh giới BIO và cung cấp tín hiệu đủ mạnh cho lớp hiếm.

SupCon theo nhãn BIO chính xác kéo các token cùng `B-X` hoặc cùng `I-X` lại gần nhau, nhưng xem `B-X` và `I-X` là cặp âm dù chúng cùng loại thực thể. Ngược lại, nếu gộp hoàn toàn hai tiền tố thì biểu diễn có thể mất tín hiệu vị trí cần cho giải mã chuỗi. Khoảng trống khoa học của bài toán là thiết kế quan hệ dương có mức độ, thay vì lựa chọn nhị phân "trùng nhãn" hoặc "trùng loại".

Nghiên cứu này có ba đóng góp chính:

- **Thứ nhất:** Đề xuất ma trận tương đồng phân cấp, trong đó cặp trùng BIO có trọng số 1 và cặp cùng loại khác tiền tố có trọng số α, đồng thời loại nhãn `O` khỏi loss tương phản.
- **Thứ hai:** Kết hợp đồng thời H-SupCon với CRF để tối ưu cả hình học biểu diễn token và tính hợp lệ toàn cục của chuỗi nhãn; nhánh tương phản được tách khỏi suy luận.
- **Thứ ba:** Phân tích tín hiệu thực nghiệm theo từng loại thực thể và xác định các ablation còn thiếu để phân biệt lợi ích của H-SupCon với thay đổi cấu hình khác.

II. Công trình liên quan

PAP_NER do La và cộng sự công bố là bộ dữ liệu nhận diện thực thể cho văn bản thủ tục hành chính tiếng Việt, gồm 162.801 câu và 205.807 thực thể thuộc năm loại: cơ quan, đối tượng, văn bản pháp luật, ngày tháng và số lượng [1]. Công trình này đã đánh giá BiLSTM+CRF, ELECTRA, XLM-R, PhoBERT và PhoBERT+CRF; trong đó PhoBERT+CRF đạt 97,95% Micro F1 trên tập kiểm thử của tác giả [1]. Đây là cơ sở đối chiếu trực tiếp cho nghiên cứu của chúng tôi.

Các bộ dữ liệu NER tiếng Việt trước đó chủ yếu tập trung vào những miền và loại thực thể khác. Chẳng hạn, PhoNER_COVID19 được xây dựng cho thông tin y tế liên quan đến COVID-19 [2]. Trong miền pháp luật Việt Nam, Nguyen và cộng sự nghiên cứu việc trích xuất tham chiếu và quan hệ giữa các tham chiếu trong văn bản pháp luật [3]. Những công trình này cho thấy nhu cầu xử lý thực thể và cấu trúc thông tin đặc thù theo miền, song khác PAP_NER về tác vụ, hệ thống nhãn hoặc dữ liệu đánh giá.

Về kiến trúc, XLM-R là mô hình tiền huấn luyện đa ngôn ngữ [4], trong khi PhoBERT và BamiBERT được phát triển cho tiếng Việt [5], [6]; ELECTRA sử dụng mục tiêu phân biệt token bị thay thế khi tiền huấn luyện [7]. Đối với gán nhãn chuỗi, CRF mô hình hóa sự phụ thuộc giữa các nhãn liên tiếp [8]. Học tương phản có giám sát tổ chức không gian

biểu diễn bằng quan hệ dương và âm [9]. CONTaiNER học khoảng cách giữa token trong NER ít mẫu [10], còn SCL-RAI đối chiếu biểu diễn ở mức span [11]. BANER cho thấy loss nhận biết ranh giới là một hướng riêng quan trọng [12]. Tuy vậy, các công trình này không giải quyết trực tiếp quan hệ phân cấp giữa `B-X` và `I-X` trong NER thủ tục hành chính đầy đủ dữ liệu, cũng chưa kết hợp quan hệ dương mềm này với CRF trong một mục tiêu chung.

Ở NER đa phương thức, CUA-MNER kết hợp CRF và học tương phản có giám sát ở mức token trong một mục tiêu end-to-end [13]. Thiết kế này cho thấy khả năng phối hợp tín hiệu phân biệt biểu diễn với ràng buộc gán nhãn chuỗi, nhưng không trực tiếp so sánh với quy trình huấn luyện hai giai đoạn. Vì vậy, lựa chọn giữa tối ưu tuần tự và tối ưu đồng thời vẫn là một câu hỏi phương pháp luận cần kiểm chứng riêng trong bối cảnh PAP_NER.

III. Dữ liệu và phương pháp

A. Bộ ngữ liệu đối chuẩn PAP_NER

PAP_NER là bộ ngữ liệu đối chuẩn quy mô lớn đầu tiên cho NER trong thủ tục hành chính tiếng Việt, được công bố trên *PLOS ONE* năm 2026 [1]. Ngữ liệu gồm các câu thuộc mô tả thủ tục hành chính được công bố trên Cổng Dịch vụ công Quốc gia và các cơ sở dữ liệu hành chính cấp tỉnh [1], [14]. Nội dung bao gồm tên cơ quan giải quyết, đối tượng thực hiện thủ tục, căn cứ pháp lý, thời hạn xử lý và các khoản phí hoặc số lượng liên quan. Văn bản đã được tách từ; những tiếng tạo thành một từ được nối bằng dấu gạch dưới, chẳng hạn `làm_việc`.

Mỗi câu được lưu thành một dãy token, mỗi token nằm trên một dòng. Trong các tệp sử dụng ở nghiên cứu này, một dòng gồm năm cột: token, nhãn từ loại, nhãn cụm từ, nhãn thực thể và một cột phụ. Các câu được ngăn cách bằng dòng trống. Bài toán nhận diện thực thể sử dụng chuỗi token làm đầu vào và nhãn thực thể làm đầu ra. Ví dụ, một đoạn trong dữ liệu có dạng:

```
05          M   I-NP   B-NG   O
ngày        N   I-NP   I-NG   O
làm_việc    V   B-VP   O      O
```

Nhãn thực thể tuân theo quy ước BIO: `B-X` đánh dấu token đầu tiên của một thực thể loại `X`, `I-X` đánh dấu các token tiếp theo trong cùng thực thể và `O` biểu thị token không thuộc thực thể nào. Có năm loại thực thể: CQ (cơ quan), ĐT (đối tượng), VBPL (văn bản pháp luật), NG (ngày hoặc khoảng thời gian) và SL (số lượng). Như vậy, bài toán sử dụng 11 nhãn ở mức token, gồm `O` và hai nhãn `B`/`I` cho mỗi loại thực thể.

Trong các thí nghiệm được báo cáo, PAP_NER được chia theo tỷ lệ 70/15/15, gồm 24.089 câu huấn luyện, 5.162 câu phát triển và 5.162 câu kiểm thử. Toàn bộ thiết lập có 34.413 câu, 783.777 token và 42.489 lượt xuất hiện thực thể. Bảng I trình bày số thực thể của từng loại.

Bảng I
Phân bố thực thể trong dữ liệu thực nghiệm.

Loại thực thể	Số lượng
CQ (cơ quan)	13.939
ĐT (đối tượng)	15.218
VBPL (văn bản pháp luật)	3.968
NG (ngày, thời gian)	8.029
SL (số lượng)	1.335
Tổng	**42.489**

B. Mô hình và cấu hình thực nghiệm

Nghiên cứu khảo sát XLM-R Base (∼270 triệu tham số), PhoBERT Base V2 (∼135 triệu), ELECTRA tiếng Việt (∼110–134 triệu) và BamiBERT (∼103 triệu). XLM-R là mô hình đa ngôn ngữ; ba nhóm còn lại hướng tới tiếng Việt [4], [5], [7], [6]. Các con số chỉ mô tả mô hình nền, chưa gồm tầng phân loại, CRF và đầu chiếu tương phản.

Các mô hình được ghép với CRF và nhánh H-SupCon, sau đó tối ưu đồng thời. Thiết lập huấn luyện chung kế thừa giao thức tìm kiếm trên tập phát triển của PAP_NER [1]; các tham số riêng của H-SupCon được quét theo Strict Micro F1 trên tập phát triển và khóa trước khi đánh giá kiểm thử.

Bảng II thay cấu hình batch 32 của benchmark PAP_NER bằng batch 128 cho nhánh tương phản, nhằm cung cấp nhiều cặp dương hơn trong mỗi bước cập nhật. AMP dùng FP16 cho encoder và đầu chiếu, nhưng CRF được ép về FP32 để tránh mất ổn định số. Mọi lựa chọn chỉ dựa trên tập phát triển; tập kiểm thử không tham gia tìm kiếm siêu tham số.

C. Two-Stage hay Joint Optimization?

Một lựa chọn phương pháp luận quan trọng là thời điểm đưa tín hiệu tương phản vào encoder. Với *Two-Stage*, encoder trước hết được fine-tune bằng loss tương phản; sau đó encoder và CRF được huấn luyện cho gán nhãn chuỗi. Cách tách này dễ phân tích từng giai đoạn, nhưng bước thứ hai có thể làm thay đổi không gian biểu diễn đã học ở bước thứ nhất. Với *Joint Optimization*, loss CRF và loss tương phản cùng lan truyền gradient qua encoder trong mỗi mini-batch. CUA-MNER là một ví dụ gần đây của thiết kế end-to-end kết hợp CRF và tương phản token-level [13].

Nghiên cứu này chọn Joint Optimization theo Phương trình (3) để duy trì đồng thời tín hiệu cấu trúc chuỗi và hình học biểu diễn. Đây là một giả thuyết thiết kế, không phải kết luận rằng Joint luôn vượt Two-Stage; phép so sánh trực tiếp hai chiến lược trên cùng encoder, seed và ngân sách huấn luyện vẫn được xem là ablation bắt buộc.

D. Hàm mất mát CRF–H-SupCon

Với biểu diễn theo từ $\mathbf{h}_i \in \mathbb{R}^d$, đầu chiếu hai tầng tạo $\mathbf{z}_i = g(\mathbf{h}_i)/\|g(\mathbf{h}_i)\|_2$. Đầu phân loại tạo điểm phát xạ cho CRF; CRF tối thiểu hóa log-hợp lý âm $\mathcal{L}_{\mathrm{CRF}}$ và dùng Viterbi khi suy luận [8]. Nhánh tương phản chỉ xét tập token thực thể $\mathcal{I}_e = \{i \mid y_i \neq \mathtt{O}\}$.

Bảng II
SIÊU THAM SỐ HUẤN LUYỆN, KHÔNG GIAN TÌM KIẾM VÀ TIÊU CHÍ LỰA CHỌN.

Siêu tham số	**Giá trị chọn**	**Không gian tìm kiếm**	**Tiêu chí lựa chọn**
Optimizer	AdamW	{Adam, AdamW, SGD}	Strict Micro F1 trên tập phát triển
Tốc độ học encoder	2×10^{-5}	$\{1\times10^{-5}, 2\times10^{-5}, 5\times10^{-5}\}$	Hội tụ ổn định
Tốc độ học CRF và đầu chiếu	1×10^{-3}	$\{5\times10^{-4}, 1\times10^{-3}, 2\times10^{-3}\}$	Đầu tác vụ hội tụ nhanh
Lịch tốc độ học	Linear decay + warm-up	{constant, linear, cosine}	F1 cuối tốt nhất
Tỷ lệ warm-up	0,1	{0,05; 0,1; 0,2}	Giảm bất ổn đầu quá trình
Epoch tối đa / patience	20 / 3	{10, 20, 30} / {2, 3, 5}	Dừng sớm theo F1 phát triển
Độ dài chuỗi tối đa	256 token	{128, 256, 512}	Bao phủ gần như toàn bộ câu
Weight decay / gradient clipping	0,01 / 1,0	{0,001; 0,01; 0,1} / {0,5; 1,0; 5,0}	Điều chuẩn và ổn định gradient
Dropout / mixed precision	0,1 / FP16	{0; 0,1; 0,2} / {FP32, FP16}	Cân bằng điều chuẩn và tốc độ; CRF tính ở FP32
Batch size B	128	{16, 32, 128}	Tăng số cặp dương tương phản trong batch
Trọng số H-SupCon λ	0,3	{0,1; 0,2; 0,3; 0,5; 0,7}	Strict Micro F1 phát triển lớn nhất
Liên kết mềm α	0,3	{0; 0,1; 0,2; 0,3; 0,4; 0,5}	F1 VBPL và chất lượng ranh giới
Nhiệt độ τ	0,07	{0,05; 0,07; 0,1; 0,15}	Phân tách mẫu âm khó ổn định

Gọi $t(y)$ là loại thực thể sau khi bỏ tiền tố BIO. Với $i \neq j$, trọng số dương phân cấp được định nghĩa:

$$w_{ij} = \begin{cases} 1, & y_i = y_j, \\ \alpha, & t(y_i) = t(y_j),\ y_i \neq y_j, \\ 0, & \text{ngược lại}, \end{cases} \qquad 0 < \alpha < 1. \quad (1)$$

Cặp trùng BIO là mẫu dương mạnh; cặp `B-X`/`I-X` cùng loại là mẫu dương mềm. Cách này duy trì liên kết ngữ nghĩa trong thực thể dài nhưng không đồng nhất hoàn toàn vai trò ranh giới. Với $\mathcal{A}(i) = \mathcal{I}_e \setminus \{i\}$ và $s_{ik} = \mathbf{z}_i^\top \mathbf{z}_k/\tau$, loss cho anchor hợp lệ là:

$$\ell_i = -\frac{1}{\sum_{j\in\mathcal{A}(i)} w_{ij}} \sum_{j\in\mathcal{A}(i)} w_{ij} \log \frac{e^{s_{ij}}}{\sum_{k\in\mathcal{A}(i)} e^{s_{ik}}}. \quad (2)$$

Chỉ các anchor có $\sum_j w_{ij} > 0$ được lấy trung bình để tránh chia cho 0. Mục tiêu cuối cùng là

$$\mathcal{L} = \mathcal{L}_{\text{CRF}} + \lambda \mathcal{L}_{\text{H-SupCon}}, \quad \lambda = 0{,}3,\ \alpha = 0{,}3,\ \tau = 0{,}07. \quad (3)$$

Loại `O` vẫn tham gia đầy đủ vào CRF nhưng không chi phối mẫu âm của H-SupCon. Khi kiểm thử, đầu chiếu và loss tương phản được bỏ; đường suy luận chỉ còn encoder, tầng phát xạ và Viterbi.

Hình 1 thể hiện hai tín hiệu bổ trợ: CRF học phụ thuộc chuyển tiếp của toàn chuỗi, còn H-SupCon tổ chức hình học biểu diễn ở mức token. Tối ưu đồng thời cho phép cả hai gradient cập nhật encoder trong cùng một bước, tránh việc không gian tương phản bị thay đổi ở một giai đoạn huấn luyện CRF tách biệt.

E. Phép đánh giá

Một thực thể chỉ được tính đúng khi cả ranh giới và loại đều khớp nhãn chuẩn. Chỉ số chính là Strict Micro F1, tính từ tổng TP, FP và FN của năm loại thực thể:

$$P_{\text{micro}} = \frac{\sum_c TP_c}{\sum_c (TP_c + FP_c)}, \quad (4)$$

$$R_{\text{micro}} = \frac{\sum_c TP_c}{\sum_c (TP_c + FN_c)}, \quad (5)$$

$$F_{1,\text{micro}} = \frac{2P_{\text{micro}}R_{\text{micro}}}{P_{\text{micro}} + R_{\text{micro}}}. \quad (6)$$

Các chỉ số theo loại và Macro F1 được báo cáo để tránh việc lớp lớn chi phối diễn giải. Điểm được tính theo chuẩn BIO bằng `seqeval` với `mode='strict'` và `scheme=IOB2` [15].

Để tách lỗi ranh giới khỏi lỗi phân loại, bốn chế độ đối sánh được dùng:

- **Strict:** đúng cả ranh giới và loại thực thể;
- **Exact:** đúng ranh giới, không xét loại thực thể;
- **Partial:** ranh giới có giao nhau, không xét loại;
- **Type:** ranh giới có giao nhau và đúng loại.

Exact giúp nhận diện lỗi phân loại khi ranh giới đã đúng; Partial và Type cho biết mô hình có định vị đúng vùng thực thể hay không. Điểm kiểm soát được chọn theo F1 thực thể trên tập phát triển; các bảng kết quả được tính trên tập kiểm thử tương ứng.

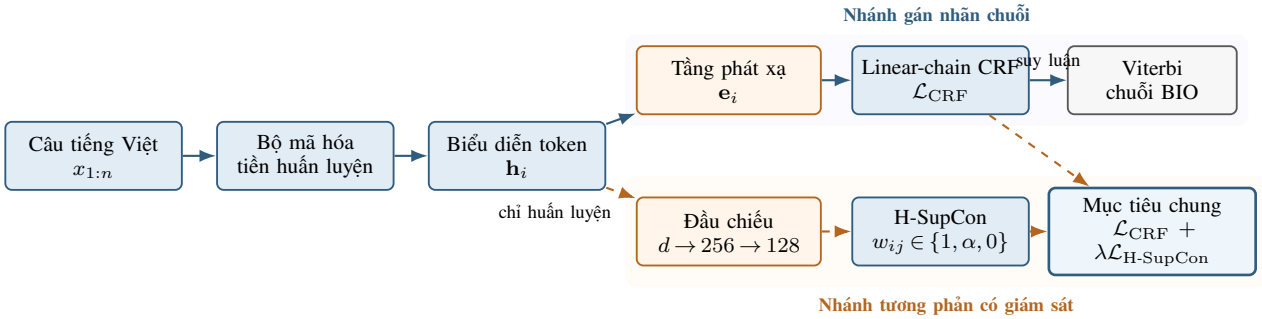
Bảng III
KẾT QUẢ STRICT MICRO Ở CẤP THỰC THỂ TRÊN PAP_NER (%).

Mô hình	**P**	**R**	**F1**
XLM-R + CRF-H-SupCon	97,89	96,67	97,28
PhoBERT V2 + CRF	98,75	97,22	97,98
PhoBERT V2 + CRF-H-SupCon	98,65	97,21	97,92
ELECTRA + CRF-H-SupCon	98,20	98,60	98,40
BamiBERT + CRF-H-SupCon	98,03	98,93	98,48

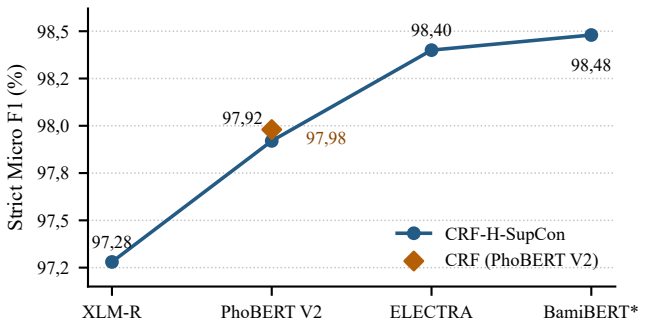
IV. KẾT QUẢ

A. So sánh tổng quan

Nhận xét 1. Trên cùng 10.278 mẫu, PhoBERT V2 + CRF-H-SupCon cao hơn XLM-R + CRF-H-SupCon 0,76 điểm precision, 0,54 điểm recall và 0,64 điểm F1.



Hình 1. Kiến trúc huấn luyện chung CRF–H-SupCon. Đường màu xanh biểu diễn luồng suy luận; đường màu cam nét đứt biểu diễn các kết nối chỉ dùng khi huấn luyện.



Hình 2. Strict Micro F1 theo mô hình nền. Điểm CRF chỉ có ở PhoBERT V2; BamiBERT (*) dùng tập kiểm thử 5.162 mẫu nên chỉ mang ý nghĩa mô tả.

Bảng IV
F1 THEO LOẠI THỰC THỂ (%).

Mô hình	CQ	ĐT	VBPL	NG	SL
XLM-R + CRF-H-SupCon	97,05	96,02	97,41	99,99	96,99
PhoBERT V2 + CRF	97,74	97,32	97,41	99,98	97,24
PhoBERT V2 + CRF-H-SupCon	97,69	97,21	97,31	99,95	97,39
ELECTRA + CRF-H-SupCon	97,80	97,80	96,80	99,70	97,40
BamiBERT + CRF-H-SupCon	98,98	98,07	95,50	99,84	98,51

Nhận xét 2. Với cùng backbone PhoBERT V2, CRF-H-SupCon đạt 98,65/97,21/97,92, thấp hơn CRF lần lượt 0,10/0,01/0,06 điểm P/R/F1; do đó lần chạy hiện tại chưa cho thấy lợi ích tổng thể của loss mới.

Nhận xét 3. ELECTRA đạt 98,20/98,60/98,40 về P/R/F1. BamiBERT có F1 98,48%, cao hơn 0,08 điểm về trị số, nhưng được đánh giá trên 5.162 mẫu nên không xếp hạng trực tiếp.

B. Tín hiệu thực nghiệm của H-SupCon

Theo loại thực thể trên 10.278 mẫu, chênh lệch PhoBERT V2 + CRF-H-SupCon trừ XLM-R + CRF-H-SupCon lần lượt là $+0{,}64$ (CQ), $+1{,}19$ (ĐT), $-0{,}10$ (VBPL), $-0{,}04$ (NG) và $+0{,}40$ điểm (SL). Kết quả cho thấy lựa chọn encoder vẫn ảnh hưởng đáng kể đến biểu diễn được tối ưu bởi cùng mục tiêu H-SupCon.

Đối chứng PhoBERT V2 + CRF là phép so sánh cùng backbone duy nhất hiện có; XLM-R, ELECTRA và BamiBERT vẫn thiếu đối chứng khi tắt nhánh tương phản. Kết luận nhân quả cần giữ nguyên encoder, split, seed, batch và CRF reduction, sau đó chỉ thay các thành phần của loss ở Phương trình (1)–(3).

C. Phân tích theo loại thực thể

Với PhoBERT V2, CRF-H-SupCon chỉ cao hơn CRF ở SL ($+0{,}15$ điểm), nhưng thấp hơn ở CQ ($-0{,}05$), ĐT ($-0{,}11$), VBPL ($-0{,}10$) và NG ($-0{,}03$). Macro F1 tương ứng là 97,91% và 97,94%. ELECTRA đạt Macro F1 97,90%, tốt nhất ở NG (99,70%) và thấp nhất ở VBPL (96,80%). BamiBERT đạt F1 thấp nhất ở VBPL (95,50%) trong log 5.162 mẫu; kết quả không được xếp hạng trực tiếp với các hàng dùng 10.278 mẫu. Bảng hiện chưa có khoảng tin cậy cho các chênh lệch theo nhãn.

D. Ablation cần thiết

Bốn cấu hình tối thiểu cần được chạy trên cùng điều kiện: (i) CRF; (ii) CRF + SupCon trùng BIO ($\alpha = 0$); (iii) CRF + H-SupCon nhưng giữ $\mathcal{O}$; và (iv) CRF + H-SupCon đầy đủ. Cần quét α, λ và τ chỉ trên tập phát triển; báo cáo tỷ lệ anchor hợp lệ theo nhãn, ít nhất ba seed, khoảng tin cậy và kiểm định cặp trên cùng tập kiểm thử. Thiết kế này lần lượt kiểm chứng vai trò của liên kết mềm, việc loại $\mathcal{O}$, độ ổn định và ý nghĩa thống kê của mức tăng. Ngoài ra, cần so sánh Two-Stage với Joint Optimization dưới cùng số bước cập nhật và ngân sách tính toán để tách lợi ích của loss khỏi lịch huấn luyện.

V. THẢO LUẬN

Trên PhoBERT V2, cấu hình CRF-H-SupCon thấp hơn CRF 0,06 điểm F1; đây là bằng chứng ghép cặp trực tiếp nhưng mới chỉ có một lần chạy. Kết quả giữa XLM-R, PhoBERT V2 và ELECTRA cho thấy ảnh hưởng của backbone, còn BamiBERT chỉ có ý nghĩa mô tả do dùng tập kiểm thử khác kích thước. CRF và H-SupCon vẫn có vai trò bổ sung về mặt thiết kế: CRF ràng buộc chuyển tiếp nhãn, còn H-SupCon thay đổi hình học biểu diễn. Đầu chiếu bị loại khi suy luận nên loss mới không thêm phép tính vào đường giải mã; chi phí huấn luyện vẫn cần đo thống nhất.

Thiếu ablation $\alpha = 0$, giữ/bỏ nhãn `O` và nhiều seed khiến chưa thể tách tác động của từng thành phần trong H-SupCon. Đây là khoảng trống thực nghiệm quan trọng nhất còn lại.

Cuối cùng, PAP_NER bắt nguồn từ thủ tục hành chính. Kết quả về VBPL trong bài đo chất lượng nhận diện **trích dẫn văn bản pháp luật bên trong thủ tục hành chính**, không chứng minh hiệu quả trên toàn bộ văn bản quy phạm pháp luật, bản án hay hợp đồng. Phạm vi này được giữ nhất quán trong tên bài, tóm tắt và kết luận.

VI. Hạn chế và hướng phát triển

A. Giá trị nội tại và độ tin cậy thống kê

Hạn chế quan trọng nhất là mỗi cấu hình hiện mới có một lần chạy được báo cáo. Quá trình fine-tune Transformer nhạy với khởi tạo tầng phân loại, thứ tự mini-batch và dropout; do đó, chênh lệch 0,64 điểm giữa XLM-R và PhoBERT V2 có thể nằm trong dao động giữa các seed. Điểm đơn lẻ chỉ mô tả lần chạy hiện tại, chưa cho phép kết luận rằng thứ hạng sẽ được bảo toàn khi huấn luyện lại. Thực nghiệm tiếp theo cần dùng tối thiểu năm seed cố định cho từng cấu hình, báo cáo trung bình, độ lệch chuẩn và khoảng tin cậy 95%. Ngoài ra, kiểm định bootstrap theo cặp nên lấy mẫu ở cấp câu hoặc cấp tài liệu trên cùng tập kiểm thử, thay vì xem từng thực thể là một quan sát độc lập.

Hiện chỉ PhoBERT V2 có đối chứng CRF trên cùng backbone; XLM-R, ELECTRA và BamiBERT chưa có cặp tương ứng. Một ablation có giá trị nhân quả phải giữ nguyên checkpoint, seed, bộ chia batch, số bước cập nhật, lịch learning rate và quy tắc chọn mô hình. Hai lần chạy chỉ được khác đúng một yếu tố: bật hoặc tắt nhánh tương phản. Cùng nguyên tắc đó, so sánh Two-Stage–Joint phải dùng cùng số lần encoder được cập nhật hoặc cùng ngân sách FLOPs; nếu không, lợi thế có thể đến từ thời gian huấn luyện dài hơn chứ không phải cách phối hợp hai mục tiêu.

B. Giới hạn của phép đo và phân tích cơ chế

Strict Micro F1 phù hợp với mục tiêu nhận diện chính xác cả ranh giới lẫn loại, nhưng bị chi phối bởi các lớp phổ biến và không cho biết lỗi xuất hiện ở vị trí nào trong thực thể. F1 theo loại ở Bảng IV mới là bước đầu. Để kiểm tra trực tiếp giả thuyết về ranh giới dài, cần phân tầng kết quả theo độ dài thực thể (1, 2–3, 4–7 và trên 7 token), đồng thời tách ba nhóm lỗi: đúng vùng nhưng sai loại, đúng loại nhưng thiếu/thừa biên, và bỏ sót hoàn toàn. Nếu H-SupCon thực sự liên kết tốt hơn `B-X` với `I-X`, mức cải thiện phải tập trung ở nhóm thực thể nhiều token và lỗi đứt ranh giới, thay vì chỉ tăng Micro F1 tổng.

Trọng số mềm $\alpha = 0,3$ hiện được dùng như nhau cho mọi loại thực thể và mọi độ dài. Giả định này đơn giản nhưng có thể không phù hợp khi cấu trúc của CQ, VBPL và SL khác nhau đáng kể. Giá trị α quá nhỏ không bổ sung đủ mẫu dương; giá trị quá lớn có nguy cơ làm mờ vai trò khác nhau của tiền tố `B` và `I`. Tương tự, việc loại nhãn `O` giúp giảm ưu thế số lượng của token ngoài thực thể, nhưng cũng bỏ qua các mẫu âm khó ngay sát biên. Vì thế, cần báo cáo tỷ lệ anchor hợp lệ theo nhãn, số cặp dương mạnh/mềm trong mỗi batch và phân bố cosine similarity trước và sau huấn luyện. Các đại lượng này cho biết loss có thay đổi hình học biểu diễn theo đúng cơ chế dự kiến hay không.

Hướng mở rộng có thể dùng α_c theo loại/độ dài và tăng dần λ sau warm-up. Do loss phụ thuộc các cặp dương trong mini-batch, thí nghiệm cần cố định danh sách batch giữa các đối chứng, ghi tỷ lệ anchor bị loại theo lớp và so sánh lấy mẫu ngẫu nhiên, phân tầng cùng hàng đợi biểu diễn. Mọi cơ chế thích nghi phải được chọn trên tập phát triển dưới cùng ngân sách tìm kiếm.

C. Khả năng khái quát và hiệu quả tính toán

PAP_NER chỉ đại diện cho ngôn ngữ thủ tục hành chính. Câu văn trong văn bản quy phạm pháp luật, bản án và hợp đồng có cấu trúc lập luận, độ dài và hệ thống trích dẫn khác. Vì vậy, kết quả hiện tại chưa chứng minh H-SupCon ổn định trước dịch chuyển miền. Đánh giá tương lai nên huấn luyện trên PAP_NER rồi kiểm thử chéo trên một tập được gán nhãn từ miền pháp lý khác; sau đó so sánh zero-shot với fine-tune ít mẫu. Cũng cần chia kết quả theo nguồn, thời gian ban hành và nhóm thủ tục để phát hiện trường hợp mô hình ghi nhớ mẫu diễn đạt quen thuộc thay vì học đặc trưng ranh giới có thể chuyển giao.

Nhánh chiếu được bỏ khi suy luận, nên kiến trúc không thêm phép tính vào đường giải mã. Tuy nhiên, điều này không đồng nghĩa chi phí tổng bằng không: huấn luyện vẫn phải tạo ma trận tương đồng giữa các token thực thể, với bộ nhớ và số phép tính tăng gần bậc hai theo số anchor trong batch. Báo cáo tiếp theo cần đo thời gian huấn luyện mỗi epoch, bộ nhớ GPU cực đại, thông lượng câu/giây, độ trễ suy luận và kích thước mô hình trong cùng môi trường. Nếu ma trận cặp trở thành nút thắt, có thể khảo sát lấy mẫu cặp theo lớp, giới hạn số anchor, hàng đợi biểu diễn qua batch hoặc khai thác hard negative cục bộ quanh biên thực thể.

Đánh giá triển khai cần đo hiệu chuẩn, khả năng từ chối và đường cong coverage–risk vì lỗi VBPL/CQ có thể ảnh hưởng truy xuất, còn lỗi SL có thể làm đổi điều kiện áp dụng. Một bộ kiểm thử stress giữ nguyên nhãn vàng nên thêm có kiểm soát lỗi OCR, dấu tiếng Việt, khoảng trắng, viết tắt và chuỗi trích dẫn; độ giảm F1 so với đối chứng phản ánh độ bền ngoài phân bố quen thuộc.

D. Đánh giá ngoại sinh và cập nhật mô hình

Giá trị ứng dụng cần được kiểm tra trên tác vụ phía sau với ba biến thể dùng chung retriever và bộ sinh: không dùng NER, dùng thực thể dự đoán và dùng nhãn vàng. Recall@k, MRR/nDCG, độ chính xác trích dẫn và tỷ lệ câu trả lời được hỗ trợ bởi nguồn cho biết lỗi CQ/VBPL có thực sự ảnh hưởng truy xuất hay không; mọi thành phần ngoài NER phải được cố định để tránh quy kết nhầm.

Khi triển khai, mỗi mô hình cần gắn với phiên bản dữ liệu, ontology nhãn, ngưỡng từ chối và bộ kiểm thử hồi quy. Phiên bản mới chỉ nên thay thế mô hình đang vận hành khi không làm giảm đáng kể F1 của lớp quan trọng và vượt qua bộ kiểm thử stress về OCR, dấu câu, viết tắt và chuỗi trích dẫn.

E. Lộ trình thực nghiệm tiếp theo

Chương trình kiểm chứng được đề xuất gồm bốn bước. *Bước 1* cô lập từng thành phần bằng chuỗi cấu hình: CRF, CRF + SupCon trùng BIO, CRF + H-SupCon có giữ O, và mô hình đầy đủ; mọi cấu hình dùng cùng siêu tham số ngoài thành phần đang xét. *Bước 2* quét α, λ và τ chỉ trên tập phát triển, sau đó khóa cấu hình trước khi chạy nhiều seed trên tập kiểm thử. *Bước 3* so sánh Two-Stage với Joint Optimization dưới cùng ngân sách cập nhật, đồng thời theo dõi riêng $\mathcal{L}_{\mathrm{CRF}}$, $\mathcal{L}_{\mathrm{H-SupCon}}$ và chuẩn gradient tại encoder để phát hiện một mục tiêu lấn át mục tiêu còn lại. *Bước 4* thực hiện đánh giá chéo miền, phân tích theo độ dài thực thể và benchmark hiệu quả tính toán.

Để bảo đảm khả năng tái lập, mỗi thí nghiệm cần lưu seed, mã checkpoint, hash cấu hình, phiên bản thư viện, quy tắc chọn epoch và toàn bộ dự đoán trên tập kiểm thử. Công bố dự đoán ở cấp câu cho phép thực hiện lại bootstrap, phân tích lỗi và so sánh cặp mà không phải huấn luyện lại mô hình. Khi các bước này hoàn tất, kết luận có thể chuyển từ "tín hiệu hứa hẹn trên một số mô hình nền" sang đánh giá định lượng về mức cải thiện, độ ổn định, chi phí và phạm vi áp dụng của H-SupCon.

VII. Kết luận

Bài viết đề xuất H-SupCon để mô hình hóa quan hệ phân cấp giữa nhãn BIO và loại thực thể, đồng thời tối ưu cùng CRF trong một mục tiêu thống nhất. XLM-R + CRF-H-SupCon và PhoBERT V2 + CRF-H-SupCon lần lượt đạt 97,28% và 97,92% Strict Micro F1 trên 10.278 mẫu; ELECTRA + CRF-H-SupCon đạt 98,40%, còn BamiBERT + CRF-H-SupCon đạt 98,48% trên 5.162 mẫu. Trên PhoBERT V2, cấu hình đề xuất thấp hơn CRF 0,06 điểm F1. Kết quả một lần chạy và chênh lệch tập kiểm thử chưa cho phép kết luận ưu thế tổng quát của loss mới. Đóng góp chính là công thức hóa quan hệ dương mềm, kiến trúc Joint Optimization không tăng đường suy luận, và một giao thức ablation gồm cả so sánh Two-Stage–Joint để kiểm chứng giả thuyết về ranh giới dài và lớp hiếm.

Tài liệu tham khảo

[1] D.-D. La, T.-B. Tran, N.-H. Du, N.-H. Dang, T.-N. Phung, and V.-K. Tran, "PAP_NER: A large-scale vietnamese administrative named entity recognition corpus and hybrid deep learning architecture," *PLOS ONE*, vol. 21, no. 7, p. e0353166, 2026. [Online]. Available: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0353166

[2] T. H. Truong, M. H. Dao, and D. Q. Nguyen, "COVID-19 named entity recognition for vietnamese," in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2021, pp. 2146–2153. [Online]. Available: https://aclanthology.org/2021.naacl-main.173/

[3] T. T. T. Nguyen, N. D. Nguyen, X. B. Ngo, and M. P. Tu, "Joint reference and relation extraction from legal documents with enhanced decoder input," *Cybernetics and Information Technologies*, vol. 23, no. 2, pp. 72–86, 2023. [Online]. Available: https://doi.org/10.2478/cait-2023-0014

[4] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Unsupervised cross-lingual representation learning at scale," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 8440–8451. [Online]. Available: https://aclanthology.org/2020.acl-main.747/

[5] D. Q. Nguyen and A. Tuan Nguyen, "PhoBERT: Pre-trained language models for vietnamese," in *Findings of the Association for Computational Linguistics: EMNLP 2020*. Association for Computational Linguistics, 2020, pp. 1037–1042. [Online]. Available: https://aclanthology.org/2020.findings-emnlp.92/

[6] D. Q. Nguyen, T. Pham, C. Tran, and L. T. Nguyen, "BamiBERT: A new BERT-based language model for vietnamese," 2026. [Online]. Available: https://arxiv.org/abs/2607.02259

[7] K. Clark, M.-T. Luong, Q. V. Le, and C. D. Manning, "ELECTRA: Pre-training text encoders as discriminators rather than generators," in *International Conference on Learning Representations*, 2020. [Online]. Available: https://openreview.net/forum?id=r1xMH1BtvB

[8] J. Lafferty, A. McCallum, and F. C. N. Pereira, "Conditional random fields: Probabilistic models for segmenting and labeling sequence data," in *Proceedings of the Eighteenth International Conference on Machine Learning*. Morgan Kaufmann, 2001, pp. 282–289. [Online]. Available: https://www.cs.columbia.edu/~jebara/6772/papers/crf.pdf

[9] P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, and D. Krishnan, "Supervised contrastive learning," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 18 661–18 673. [Online]. Available: https://papers.neurips.cc/paper_files/paper/2020/hash/d89a66c7c80a29b1bdbab0f2a1a94af8-Abstract.html

[10] S. S. S. Das, A. Katiyar, R. Passonneau, and R. Zhang, "CONTaiNER: Few-shot named entity recognition via contrastive learning," in *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2022, pp. 6338–6353. [Online]. Available: https://aclanthology.org/2022.acl-long.439/

[11] S. Si, S. Zeng, J. Lin, and B. Chang, "SCL-RAI: Span-based contrastive learning with retrieval augmented inference for unlabeled entity problem in NER," in *Proceedings of the 29th International Conference on Computational Linguistics*. International Committee on Computational Linguistics, 2022, pp. 2313–2318. [Online]. Available: https://aclanthology.org/2022.coling-1.202/

[12] Q. Guo, Y. Dong, L. Tian, Z. Kang, Y. Zhang, and S. Wang, "BANER: Boundary-aware LLMs for few-shot named entity recognition," in *Proceedings of the 31st International Conference on Computational Linguistics*. Association for Computational Linguistics, 2025, pp. 10 375–10 389. [Online]. Available: https://aclanthology.org/2025.coling-main.691/

[13] X. Yang, R. Zhao, and H. Li, "A contrastive and uncertainty-aware framework for multimodal named entity recognition," *Electronics*, vol. 15, no. 13, p. 2770, 2026. [Online]. Available: https://www.mdpi.com/2079-9292/15/13/2770

[14] D.-D. La, T.-B. Tran, N.-H. Du, N.-H. Dang, T.-N. Phung, and V.-K. Tran, "PAP_NER dataset," 2025. [Online]. Available: https://doi.org/10.5281/zenodo.18044019

[15] H. Nakayama, "seqeval: A python framework for sequence labeling evaluation," 2018. [Online]. Available: https://github.com/chakki-works/seqeval