# Học tương phản có giám sát phân cấp ở mức token kết hợp CRF cho nhận dạng thực thể trong văn bản thủ tục hành chính tiếng Việt

Nguyễn Thị Bích Nguyên, Lê Trung Kiên, Huỳnh Tiến Đạt
Đặng Thành Tài, Nguyễn Trường Giang và Nguyễn Thành Hưng
Khoa Công nghệ Thông tin 2, Học viện Công nghệ Bưu chính Viễn thông, Việt Nam
Email tác giả liên hệ: ntbichnguyen@ptithcm.edu.vn

***Tóm tắt*—Nhận diện thực thể trong văn bản hành chính tiếng Việt gặp khó khăn khi phân biệt loại và xác định ranh giới các cụm từ dài. Bài báo đề xuất học tương phản có giám sát phân cấp (H-SupCon) ở mức token, kết hợp với trường ngẫu nhiên có điều kiện (CRF). H-SupCon gán trọng số phân biệt cho cặp trùng nhãn BIO và cặp cùng loại khác tiền tố `B/I`, đồng thời loại nhãn `O` khỏi nhánh tương phản. Mô hình tối ưu đồng thời hai mục tiêu trên bộ mã hóa dùng chung; đầu chiếu được bỏ khi suy luận. Trên 10.278 mẫu kiểm thử PAP_NER, XLM-R và PhoBERT V2 kết hợp CRF–H-SupCon lần lượt đạt Micro F1 khớp cả biên và loại là 97,28% và 97,92%. BamiBERT đạt 98,48% trên một tập kiểm thử riêng gồm 5.162 mẫu, không dùng để xếp hạng trực tiếp với hai cấu hình trên. Phân tích theo loại cho thấy hiệu suất thay đổi giữa các nhóm thực thể và bộ mã hóa. Số lần chạy hạn chế và đối chứng chưa đầy đủ đòi hỏi thêm thí nghiệm có kiểm soát để xác định đóng góp riêng của H-SupCon.**

***Từ khóa*—nhận diện thực thể, văn bản hành chính tiếng Việt, học tương phản có giám sát phân cấp, CRF, gán nhãn BIO, PAP_NER.**

## I. Giới thiệu

Văn bản thủ tục hành chính thường chứa tên cơ quan thực hiện, đối tượng áp dụng, thời điểm, số lượng và căn cứ pháp lý. Một hệ thống NER có thể chuyển các đoạn văn bản này thành các thực thể có ranh giới và loại xác định, phục vụ tìm kiếm, đối chiếu quy định và hỗ trợ xử lý hồ sơ. Khó khăn nổi bật là các cụm tên cơ quan hoặc trích dẫn văn bản pháp luật có thể dài, chứa ký hiệu và dễ bị tách sai ranh giới.

PAP_NER là bộ dữ liệu công khai gồm năm loại thực thể: cơ quan (CQ), đối tượng (ĐT), văn bản pháp luật (VBPL), ngày tháng (NG) và số lượng (SL) [1]. Trong tập huấn luyện cục bộ, số token `I-VBPL` gấp khoảng 3,31 lần `B-VBPL`; đồng thời SL chỉ chiếm 7,15% tổng số thực thể của toàn bộ dữ liệu. Hai đặc điểm này gợi ra một khoảng trống: mục tiêu học biểu diễn cần bảo toàn quan hệ giữa phần mở đầu và phần thân của thực thể dài, nhưng vẫn phải giữ thông tin ranh giới BIO và cung cấp tín hiệu đủ mạnh cho lớp hiếm.

SupCon theo nhãn BIO chính xác kéo các token cùng `B-X` hoặc cùng `I-X` lại gần nhau, nhưng xem `B-X` và `I-X` là cặp âm dù chúng cùng loại thực thể. Ngược lại, nếu gộp hoàn toàn hai tiền tố thì biểu diễn có thể mất tín hiệu vị trí cần cho giải mã chuỗi. Khoảng trống khoa học của bài toán là thiết kế quan hệ dương có mức độ, thay vì lựa chọn nhị phân "trùng nhãn" hoặc "trùng loại".

Nghiên cứu này có ba đóng góp chính:

- **Thứ nhất:** Đề xuất ma trận trọng số quan hệ phân cấp, trong đó cặp trùng BIO có trọng số 1 và cặp cùng loại khác tiền tố có trọng số $\alpha$, đồng thời loại nhãn `O` khỏi loss tương phản.
- **Thứ hai:** Kết hợp đồng thời H-SupCon với CRF để tối ưu cả hình học biểu diễn token và phụ thuộc nhãn toàn chuỗi; nhánh tương phản được tách khỏi suy luận.
- **Thứ ba:** Phân tích tín hiệu thực nghiệm theo từng loại thực thể và xác định các ablation còn thiếu để phân biệt lợi ích của H-SupCon với thay đổi cấu hình khác.

## II. Công trình liên quan

PAP_NER do La và cộng sự công bố là bộ dữ liệu nhận diện thực thể cho văn bản thủ tục hành chính tiếng Việt, gồm 162.801 câu và 205.807 thực thể thuộc năm loại: cơ quan, đối tượng, văn bản pháp luật, ngày tháng và số lượng [1]. Công trình này đã đánh giá BiLSTM+CRF, ELECTRA, XLM-R, PhoBERT và PhoBERT+CRF; trong đó PhoBERT+CRF đạt 97,95% Micro F1 trên tập kiểm thử của tác giả [1]. Đây là mốc tham khảo; so sánh trực tiếp còn đòi hỏi xác nhận cùng phiên bản dữ liệu, cách đánh giá và giao thức huấn luyện.

Các bộ dữ liệu NER tiếng Việt trước đó chủ yếu tập trung vào những miền và loại thực thể khác. Chẳng hạn, PhoNER_COVID19 được xây dựng cho thông tin y tế liên quan đến COVID-19 [2]. Trong miền pháp luật Việt Nam, Nguyen và cộng sự nghiên cứu việc trích xuất tham chiếu và quan hệ giữa các tham chiếu trong văn bản pháp luật [3]. Những công trình này cho thấy nhu cầu xử lý thực thể và cấu trúc thông tin đặc thù theo miền, song khác PAP_NER về tác vụ, hệ thống nhãn hoặc dữ liệu đánh giá.

Về kiến trúc, XLM-R là mô hình tiền huấn luyện đa ngôn ngữ [4], trong khi PhoBERT và BamiBERT được phát triển cho tiếng Việt [5], [6]; ELECTRA sử dụng mục tiêu phân biệt token bị thay thế khi tiền huấn luyện [7]. Đối với gán nhãn chuỗi, CRF mô hình hóa sự phụ thuộc giữa các nhãn liên tiếp [8]. Học tương phản có giám sát tổ chức không gian biểu diễn bằng quan hệ dương và âm [9]. CONTaiNER học khoảng cách giữa token trong NER ít mẫu [10], còn SCL-RAI

đối chiếu biểu diễn ở mức span [11]. BANER cho thấy loss nhận biết ranh giới là một hướng riêng quan trọng [12]. Trong bối cảnh đó, bài viết tập trung vào quan hệ phân cấp giữa `B-X` và `I-X` trong NER thủ tục hành chính, thông qua quan hệ dương có trọng số được tối ưu đồng thời với CRF.

Ở NER đa phương thức, CUA-MNER kết hợp CRF và học tương phản có giám sát ở mức token trong một mục tiêu end-to-end [13]. Thiết kế này cho thấy khả năng phối hợp tín hiệu phân biệt biểu diễn với ràng buộc gán nhãn chuỗi, nhưng không trực tiếp so sánh với quy trình huấn luyện hai giai đoạn. Vì vậy, lựa chọn giữa tối ưu tuần tự và tối ưu đồng thời vẫn là một câu hỏi phương pháp luận cần kiểm chứng riêng trong bối cảnh PAP_NER.

## III. Dữ liệu và phương pháp

### A. Bộ ngữ liệu đối chuẩn PAP_NER

PAP_NER là bộ ngữ liệu đối chuẩn quy mô lớn đầu tiên cho NER trong thủ tục hành chính tiếng Việt, được công bố trên *PLOS ONE* năm 2026 [1]. Ngữ liệu gồm các câu thuộc mô tả thủ tục hành chính được công bố trên Cổng Dịch vụ công Quốc gia và các cơ sở dữ liệu hành chính cấp tỉnh [1], [14]. Nội dung bao gồm tên cơ quan giải quyết, đối tượng thực hiện thủ tục, căn cứ pháp lý, thời hạn xử lý và các khoản phí hoặc số lượng liên quan. Văn bản đã được tách từ; những tiếng tạo thành một từ được nối bằng dấu gạch dưới, chẳng hạn `làm_việc`.

Mỗi câu được lưu thành một dãy token, mỗi token nằm trên một dòng. Trong các tệp sử dụng ở nghiên cứu này, một dòng gồm năm cột: token, nhãn từ loại, nhãn cụm từ, nhãn thực thể và một cột phụ. Các câu được ngăn cách bằng dòng trống. Bài toán nhận diện thực thể sử dụng chuỗi token làm đầu vào và nhãn thực thể làm đầu ra. Ví dụ, một đoạn trong dữ liệu có dạng:

```
05          M   I-NP   B-NG   O
ngày        N   I-NP   I-NG   O
làm_việc    V   B-VP   O      O
```

Nhãn thực thể tuân theo quy ước BIO: `B-X` đánh dấu token đầu tiên của một thực thể loại `X`, `I-X` đánh dấu các token tiếp theo trong cùng thực thể và `O` biểu thị token không thuộc thực thể nào. Có năm loại thực thể: CQ (cơ quan), ĐT (đối tượng), VBPL (văn bản pháp luật), NG (ngày hoặc khoảng thời gian) và SL (số lượng). Như vậy, bài toán sử dụng 11 nhãn ở mức token, gồm `O` và hai nhãn `B`/`I` cho mỗi loại thực thể.

Đếm trực tiếp các tệp dữ liệu cục bộ cho kết quả 142.218 câu huấn luyện, 10.305 câu phát triển và 10.278 câu kiểm thử, tổng cộng 162.801 câu và 3.711.201 token. Bảng I thống kê lượt bắt đầu thực thể (nhãn `B-X`) trên ba tập. Hai log XLM-R và PhoBERT V2 H-SupCon ghi nhận 10.278 mẫu kiểm thử và 243.616 token, phù hợp về kích thước với tệp test cục bộ; chưa có mã băm trong log để xác nhận đồng nhất từng mẫu. Riêng log BamiBERT có 5.162 mẫu, nên được trình bày như một thiết lập đánh giá riêng, chưa xác định đầy đủ nguồn chia tập.

Bảng I
Phân bố thực thể theo nhãn B-X trong dữ liệu cục bộ.

| Loại thực thể | Số lượng |
|---|---|
| CQ (cơ quan) | 62.915 |
| ĐT (đối tượng) | 67.001 |
| VBPL (văn bản pháp luật) | 25.522 |
| NG (ngày, thời gian) | 35.647 |
| SL (số lượng) | 14.722 |
| **Tổng** | **205.807** |

### B. Mô hình và cấu hình thực nghiệm

Nghiên cứu khảo sát XLM-R, PhoBERT V2, ELECTRA và BamiBERT. XLM-R là mô hình đa ngôn ngữ; PhoBERT và BamiBERT hướng tới tiếng Việt, còn ELECTRA sử dụng mục tiêu phát hiện token bị thay thế khi tiền huấn luyện [4], [5], [7], [6]. Các mô hình được ghép với CRF và nhánh H-SupCon để tối ưu đồng thời. Bảng II ghi cấu hình và không gian khảo sát được mô tả trong tài liệu thiết kế. Chưa có đầy đủ log cấu hình và lịch sử quét để xác nhận các giá trị này đã được áp dụng đồng nhất cho mọi hàng kết quả. Giao thức kiểm chứng yêu cầu chỉ chọn siêu tham số trên tập phát triển trước khi đánh giá kiểm thử.

Cấu hình mô tả dùng batch 128 nhằm tăng cơ hội có cặp dương trong mỗi bước cập nhật; AMP dùng FP16 cho encoder và đầu chiếu, còn CRF dùng FP32. Các lựa chọn này cần được đối chiếu với cấu hình thực thi; bảng không thay thế báo cáo kết quả quét siêu tham số trên tập phát triển.

### C. Chiến lược tối ưu hóa: hai giai đoạn và đồng thời

Với *Two-Stage*, encoder được fine-tune bằng loss tương phản trước, sau đó huấn luyện cùng CRF; giai đoạn sau vì thế có thể ghi đè không gian biểu diễn đã học. *Joint Optimization* truyền đồng thời hai gradient qua encoder trong mỗi mini-batch; CUA-MNER là một thiết kế token-level gần đây theo hướng này [13]. Bài báo chọn Joint theo Phương trình (7) như một giả thuyết thiết kế. So sánh công bằng với Two-Stage vẫn phải giữ nguyên encoder, seed và số lần cập nhật.

### D. Cơ sở học tương phản có giám sát

Hàm mất mát tương phản (*contrastive loss*) học biểu diễn bằng cách tăng mức tương đồng với mẫu dương so với mẫu âm. Mỗi mẫu được chọn làm điểm tham chiếu (*anchor*); trong học có giám sát, nhãn xác định quan hệ dương/âm [9]. Ở đây, mỗi token hợp lệ có nhãn vàng $y_i$ và biểu diễn chuẩn hóa $\mathbf{z}_i = g(\mathbf{h}_i)/\|g(\mathbf{h}_i)\|_2$, với $\mathbf{h}_i$ là đầu ra encoder và $g$ là đầu chiếu. Trong biến thể SupCon theo BIO xét trên token thực thể, đặt $\mathcal{I}_e = \{i \mid y_i \neq \mathrm{O}\}$, $\mathcal{A}(i) = \mathcal{I}_e \setminus \{i\}$ và $\mathcal{P}(i) = \{j \in \mathcal{A}(i) \mid y_j = y_i\}$. Với $\mathcal{V}_0 = \{i \in \mathcal{I}_e \mid |\mathcal{P}(i)| > 0\}$, SupCon lấy trung bình log-xác suất của các mẫu dương:

$$\mathcal{L}_{\mathrm{SupCon}} = -\frac{1}{|\mathcal{V}_0|} \sum_{i \in \mathcal{V}_0} \frac{1}{|\mathcal{P}(i)|} \sum_{j \in \mathcal{P}(i)} \log \frac{\exp(\mathbf{z}_i^\top \mathbf{z}_j / \tau)}{\sum_{k \in \mathcal{A}(i)} \exp(\mathbf{z}_i^\top \mathbf{z}_k / \tau)}. \tag{1}$$

Bảng II
CẤU HÌNH HUẤN LUYỆN VÀ PHẠM VI KHẢO SÁT THEO TÀI LIỆU THIẾT KẾ.

| Siêu tham số | Giá trị cấu hình | Không gian tìm kiếm | Mục đích / tiêu chí dự kiến |
|---|---|---|---|
| Optimizer | AdamW | {Adam, AdamW, SGD} | Strict Micro F1 trên tập phát triển |
| Tốc độ học encoder | $2\times10^{-5}$ | $\{1\times10^{-5}, 2\times10^{-5}, 5\times10^{-5}\}$ | Hội tụ ổn định |
| Tốc độ học CRF và đầu chiếu | $1\times10^{-3}$ | $\{5\times10^{-4}, 1\times10^{-3}, 2\times10^{-3}\}$ | Đầu tác vụ hội tụ nhanh |
| Lịch tốc độ học | Linear decay + warm-up | {constant, linear, cosine} | F1 cuối tốt nhất |
| Tỷ lệ warm-up | 0,1 | {0,05; 0,1; 0,2} | Giảm bất ổn đầu quá trình |
| Epoch tối đa / patience | 20 / 3 | {10, 20, 30} / {2, 3, 5} | Dừng sớm theo F1 phát triển |
| Độ dài chuỗi tối đa | 256 token | {128, 256, 512} | Kiểm tra tỷ lệ câu bị cắt |
| Weight decay / gradient clipping | 0,01 / 1,0 | {0,001; 0,01; 0,1} / {0,5; 1,0; 5,0} | Điều chuẩn và ổn định gradient |
| Dropout / mixed precision | 0,1 / FP16 | {0; 0,1; 0,2} / {FP32, FP16} | Cân bằng điều chuẩn và tốc độ; CRF tính ở FP32 |
| Batch size $B$ | 128 | {16, 32, 128} | Tăng số cặp dương tương phản trong batch |
| Trọng số H-SupCon $\lambda$ | 0,3 | {0,1; 0,2; 0,3; 0,5; 0,7} | Strict Micro F1 phát triển lớn nhất |
| Liên kết mềm $\alpha$ | 0,3 | {0; 0,1; 0,2; 0,3; 0,4; 0,5} | F1 VBPL và chất lượng ranh giới |
| Nhiệt độ $\tau$ | 0,07 | {0,05; 0,07; 0,1; 0,15} | Phân tách mẫu âm khó ổn định |

Nhiệt độ $\tau > 0$ điều chỉnh độ tập trung của phân bố so sánh; tích vô hướng giữa các vector đơn vị là độ tương đồng cosine. Mẫu số gồm cả mẫu dương và âm, nhưng loại chính anchor. Quan hệ theo BIO khiến `B-X` và `I-X` thuộc nhóm âm dù cùng loại thực thể; H-SupCon bên dưới thay quan hệ nhị phân này bằng trọng số phân cấp. Nếu $\mathcal{V}_0$ rỗng, quy ước loss bằng 0. Padding và token đặc biệt không được đưa vào tập so sánh.

### *E. Hàm mất mát đề xuất CRF–H-SupCon*

Cùng biểu diễn token $\mathbf{h}_i \in \mathbb{R}^d$ được đưa vào hai nhánh huấn luyện có vai trò khác nhau.

**Trường ngẫu nhiên có điều kiện (CRF).** CRF (*Conditional Random Field*) là mô hình đồ thị vô hướng mô tả phân bố xác suất có điều kiện của chuỗi nhãn đầu ra khi biết chuỗi đầu vào [8]. Bài viết sử dụng CRF chuỗi tuyến tính bậc nhất: điểm phát xạ đánh giá mức phù hợp của nhãn tại từng token, còn điểm chuyển tiếp mô hình hóa quan hệ giữa hai nhãn liên tiếp. Phân bố được chuẩn hóa trên toàn bộ chuỗi, cho phép lựa chọn chuỗi BIO có điểm cao nhất thay vì quyết định từng nhãn độc lập. Trong CRF–H-SupCon, CRF học phụ thuộc nhãn, còn H-SupCon bổ sung mục tiêu học biểu diễn token.

**Mất mát CRF.** Với câu $\mathbf{x}$ dài $n$, gọi $\mathbf{e}_i[y_i]$ là điểm phát xạ của nhãn $y_i$ và $A_{u,v}$ là điểm chuyển từ nhãn $u$ sang $v$. Với $y_0$ là trạng thái bắt đầu và $y_{n+1}$ là trạng thái kết thúc, điểm và xác suất chuỗi nhãn là

$$S(\mathbf{x},\mathbf{y}) = \sum_{i=1}^{n}\big(\mathbf{e}_i[y_i] + A_{y_{i-1},y_i}\big) + A_{y_n,y_{n+1}},$$
$$p_{\mathrm{CRF}}(\mathbf{y}\mid\mathbf{x}) = \frac{\exp S(\mathbf{x},\mathbf{y})}{\sum_{\mathbf{y}'\in\mathcal{Y}(\mathbf{x})}\exp S(\mathbf{x},\mathbf{y}')}. \tag{2}$$

Với mini-batch $\mathcal{B}$, CRF tối thiểu hóa log-hợp lý âm

$$\mathcal{L}_{\mathrm{CRF}} = -\frac{1}{|\mathcal{B}|}\sum_{(\mathbf{x},\mathbf{y})\in\mathcal{B}}\log p_{\mathrm{CRF}}(\mathbf{y}\mid\mathbf{x}), \tag{3}$$

trong đó $\mathcal{Y}(\mathbf{x})$ là tập chuỗi nhãn được phép. CRF học điểm phát xạ và điểm chuyển tiếp; tính hợp lệ BIO chỉ được bảo đảm nếu có thêm mặt nạ chuyển tiếp cứng. Viterbi được dùng để tìm chuỗi có điểm lớn nhất khi suy luận [8].

**Mất mát tương phản phân cấp.** H-SupCon dùng đầu chiếu hai tầng và tập token thực thể như Mục III-D, nhưng phân biệt hai mức quan hệ dương thay cho chỉ xét nhãn BIO trùng nhau. Gọi $t(y)$ là loại thực thể sau khi bỏ tiền tố BIO. Với $i \neq j$:

$$w_{ij} = \begin{cases} 1, & y_i = y_j, \\ \alpha, & t(y_i) = t(y_j),\ y_i \neq y_j, \\ 0, & \text{ngược lại}, \end{cases} \qquad 0 \le \alpha \le 1. \tag{4}$$

Cặp trùng BIO là mẫu dương mạnh; cặp `B-X`/`I-X` cùng loại là mẫu dương mềm khi $0 < \alpha < 1$. Cơ chế này hướng tới liên kết biểu diễn cùng loại nhưng vẫn ưu tiên quan hệ trùng BIO. Với $\mathcal{A}(i) = \mathcal{I}_e \setminus \{i\}$ và $s_{ik} = \mathbf{z}_i^\top \mathbf{z}_k/\tau$, loss cho anchor hợp lệ là:

$$\ell_i = -\frac{1}{\sum_{j\in\mathcal{A}(i)} w_{ij}}\sum_{j\in\mathcal{A}(i)} w_{ij}\log\frac{e^{s_{ij}}}{\sum_{k\in\mathcal{A}(i)} e^{s_{ik}}}. \tag{5}$$

Đặt $\mathcal{V} = \{i \in \mathcal{I}_e \mid \sum_{j\in\mathcal{A}(i)} w_{ij} > 0\}$, mất mát của nhánh tương phản là

$$\mathcal{L}_{\text{H-SupCon}} = \frac{1}{|\mathcal{V}|}\sum_{i\in\mathcal{V}}\ell_i. \tag{6}$$

Nếu $\mathcal{V} = \varnothing$, quy ước $\mathcal{L}_{\text{H-SupCon}} = 0$; nếu không, chỉ lấy trung bình trên anchor có tổng trọng số dương. Khi $\alpha = 0$, loss trở về SupCon trùng BIO với cùng tập so sánh; khi $\alpha = 1$, các token cùng loại có trọng số bằng nhau. Do trọng số được chuẩn hóa theo từng anchor, $\alpha$ điều chỉnh quan hệ tương đối giữa hai nhóm dương, còn $\lambda$ điều chỉnh đóng góp toàn nhánh. Các cặp được lấy trên token thực thể trong mini-batch, kể cả khác câu.

**Mục tiêu tối ưu chung.** Hai định nghĩa trên được kết hợp:

$$\mathcal{L}_{\text{joint}} = \mathcal{L}_{\mathrm{CRF}} + \lambda\mathcal{L}_{\text{H-SupCon}}, \quad \lambda = 0{,}3,\ \alpha = 0{,}3,\ \tau = 0{,}07. \tag{7}$$

Gradient từ hai số hạng được cộng tại encoder dùng chung: CRF học phụ thuộc nhãn toàn chuỗi, còn H-SupCon định hướng biểu diễn theo trọng số quan hệ 1 và $\alpha$. Nhãn `O` vẫn tham gia đầy đủ vào CRF nhưng không chi phối nhánh tương phản. Khi kiểm thử, đầu chiếu bị loại; đường suy luận chỉ còn

encoder, tầng phát xạ và Viterbi, nên loss mới không làm tăng chi phí suy luận.

Hình 1 thể hiện hai tín hiệu bổ trợ: CRF học phụ thuộc chuyển tiếp của toàn chuỗi, còn H-SupCon tổ chức hình học biểu diễn ở mức token. Tối ưu đồng thời cho phép cả hai gradient cập nhật encoder trong cùng một bước. Cách thiết kế này duy trì hai mục tiêu trong quá trình cập nhật, nhưng chưa bảo đảm chúng luôn bổ trợ nhau.

### *F. Phép đánh giá*

Một thực thể chỉ được tính đúng khi cả ranh giới và loại đều khớp nhãn chuẩn. Chỉ số chính là Micro F1 khớp cả biên và loại (gọi tắt là Strict Micro F1 trong biểu đồ), tính từ tổng $TP$, $FP$ và $FN$ của năm loại thực thể:

$$P_{\text{micro}} = \frac{\sum_c TP_c}{\sum_c (TP_c + FP_c)}, \tag{8}$$

$$R_{\text{micro}} = \frac{\sum_c TP_c}{\sum_c (TP_c + FN_c)}, \tag{9}$$

$$F_{1,\text{micro}} = \frac{2P_{\text{micro}}R_{\text{micro}}}{P_{\text{micro}} + R_{\text{micro}}}. \tag{10}$$

Macro F1 là trung bình cộng F1 của năm loại thực thể, không bao gồm nhãn `O`. Trong log nguồn, `phrases`, `Found` và `correct` tương ứng với số thực thể vàng, dự đoán và đúng; do đó $TP = \texttt{correct}$, $FP = \texttt{Found} - TP$ và $FN = \texttt{phrases} - TP$. Số liệu được quy đổi sang phần trăm và làm tròn đến hai chữ số thập phân.

Định nghĩa khớp cả biên và loại ở đây cần được phân biệt với chế độ `seqeval strict/IOB2`: log hiện có chưa xác nhận thư viện, phiên bản và cách xử lý chuỗi BIO không hợp lệ. Chẳng hạn, test cục bộ có 20.977 nhãn `B-X`, trong khi log ghi 20.979 thực thể vàng. Cần đánh giá lại từ dự đoán gốc bằng một bộ đánh giá thống nhất trước khi đối chiếu tuyệt đối với benchmark [15].

## IV. Kết quả

### *A. So sánh tổng quan*

Kết quả so sánh cho thấy sự khác biệt về hiệu suất giữa các kiến trúc Transformer được đánh giá, đồng thời làm rõ tác động quan sát được của việc tích hợp học tương phản có giám sát phân cấp (H-SupCon) vào CRF. Ba hàng XLM-R, PhoBERT V2 H-SupCon và BamiBERT được đối chiếu với log ngày 14/10/2026. Hai hàng PhoBERT V2 + CRF và ELECTRA (†) được giữ từ bảng tổng hợp hiện có nhưng chưa tìm thấy log nguồn; mọi nhận xét liên quan đến hai hàng này còn mang tính tạm thời.

**Hiệu suất giữa các mô hình Transformer nền tảng (Performance Across Transformer Backbones).** Khi được đánh giá trên cùng tập kiểm thử gồm 10.278 mẫu, PhoBERT V2 + CRF-H-SupCon đạt cao hơn XLM-R + CRF-H-SupCon lần lượt 0,76; 0,54 và 0,64 điểm phần trăm về Precision, Recall và F1-score. Sự cải thiện nhất quán này gợi ý lợi thế tiềm năng của mô hình tiền huấn luyện chuyên biệt cho tiếng Việt so với biểu diễn đa ngôn ngữ trong NER văn bản hành chính. Nói cách khác, biểu diễn ngữ cảnh đơn ngữ có thể nắm bắt tốt hơn các đặc trưng ngôn ngữ và cách diễn đạt chuyên biệt của miền này.

Bảng III
KẾT QUẢ MICRO KHỚP BIÊN VÀ LOẠI TRÊN PAP_NER (%). †: CHƯA ĐỐI CHIẾU LOG NGUỒN; BAMIBERT DÙNG TẬP TEST RIÊNG.

| Mô hình | P | R | F1 |
|---|---|---|---|
| XLM-R + CRF-H-SupCon | 97,89 | 96,67 | 97,28 |
| PhoBERT V2 + CRF† | 98,75 | 97,22 | 97,98 |
| PhoBERT V2 + CRF-H-SupCon | 98,65 | 97,21 | 97,92 |
| ELECTRA + CRF-H-SupCon† | 98,20 | 98,60 | 98,40 |
| BamiBERT + CRF-H-SupCon | 98,03 | 98,93 | 98,48 |

Bảng IV
F1 THEO LOẠI THỰC THỂ (%). †: CHƯA ĐỐI CHIẾU LOG NGUỒN.

| Mô hình | CQ | ĐT | VBPL | NG | SL |
|---|---|---|---|---|---|
| XLM-R + CRF-H-SupCon | 97,05 | 96,02 | 97,41 | 99,99 | 96,99 |
| PhoBERT V2 + CRF† | 97,74 | 97,32 | 97,41 | 99,98 | 97,24 |
| PhoBERT V2 + CRF-H-SupCon | 97,69 | 97,21 | 97,31 | 99,95 | 97,39 |
| ELECTRA + CRF-H-SupCon† | 97,80 | 97,80 | 96,80 | 99,70 | 97,40 |
| BamiBERT + CRF-H-SupCon | 98,98 | 98,07 | 95,50 | 99,84 | 98,51 |

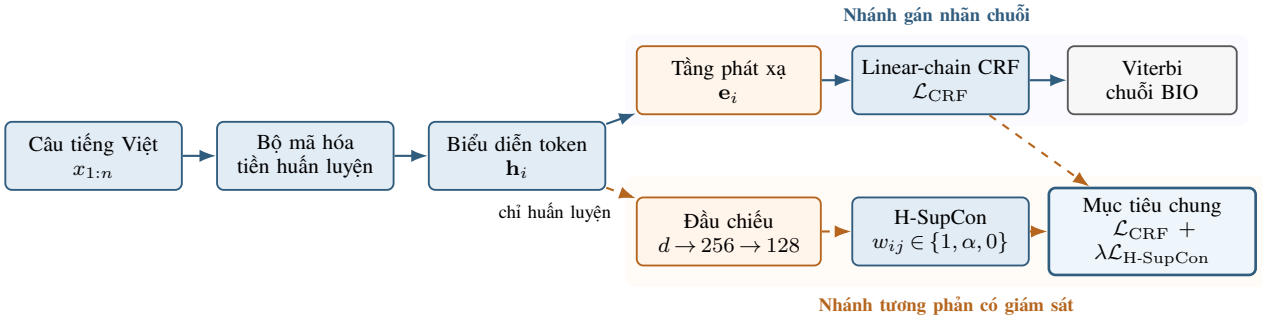
**Đối chứng PhoBERT V2 + CRF.** So với XLM-R + CRF-H-SupCon trên cùng 10.278 mẫu, PhoBERT V2 + CRF cao hơn 0,86 điểm Precision, 0,55 điểm Recall và 0,70 điểm F1. Tuy nhiên, so sánh này đồng thời thay đổi backbone và hàm mất mát. Phép đối chứng chặt chẽ hơn trên cùng PhoBERT V2 cho thấy CRF đạt 98,75/97,22/97,98 về P/R/F1, cao hơn CRF-H-SupCon 0,10/0,01/0,06 điểm. Vì vậy, lần chạy hiện tại chưa cho thấy H-SupCon cải thiện F1 tổng thể trên PhoBERT V2.

**So sánh mô tả giữa các cấu hình.** Theo bảng tổng hợp, trong các mô hình được đánh giá trên cùng 10.278 mẫu, ELECTRA + CRF-H-SupCon đạt F1 cao nhất (98,40%), cao hơn PhoBERT V2 và XLM-R tương ứng 0,48 và 1,12 điểm F1. So với PhoBERT V2, ELECTRA giảm 0,45 điểm Precision nhưng tăng 1,39 điểm Recall, qua đó nâng F1 thêm 0,48 điểm. BamiBERT đạt trị số F1 lớn nhất toàn bảng (98,48%), chỉ cao hơn ELECTRA 0,08 điểm, nhưng kết quả trên 5.162 mẫu chỉ mang tính mô tả và không được dùng để xếp hạng trực tiếp.

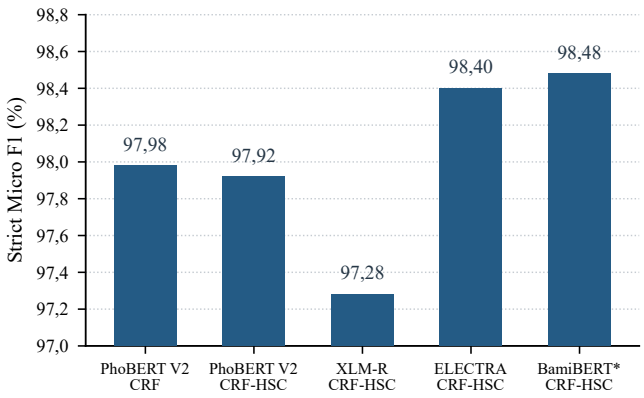
### *B. Phân tích theo loại thực thể*

Kết quả trong Bảng IV cho thấy hiệu suất nhận diện không đồng nhất giữa các loại thực thể. Đối chứng trên cùng PhoBERT V2 cho phép quan sát sự thay đổi khi bổ sung H-SupCon, trong khi so sánh giữa các backbone phản ánh khác biệt của toàn bộ cấu hình mô hình. Vì vậy, cần phân biệt cải thiện theo từng nhãn với đóng góp độc lập của mục tiêu học tương phản phân cấp.

**Tác động của H-SupCon theo từng loại thực thể.** Trên PhoBERT V2, việc bổ sung H-SupCon chỉ cải thiện F1 của nhãn SL, từ 97,24% lên 97,39%, tương ứng $+0{,}15$ điểm phần trăm. Ngược lại, F1 giảm ở CQ ($-0{,}05$ điểm), ĐT ($-0{,}11$ điểm), VBPL ($-0{,}10$ điểm) và NG ($-0{,}03$ điểm). Mức tăng cục bộ ở SL gợi ý khả năng hỗ trợ học biểu diễn cho các biểu




Hình 1. Kiến trúc huấn luyện chung CRF–H-SupCon. Đường màu xanh biểu diễn luồng suy luận; đường màu cam nét đứt biểu diễn các kết nối chỉ dùng khi huấn luyện.




Hình 2. So sánh Strict Micro F1 của năm cấu hình mô hình. BamiBERT (*) được đánh giá trên 5.162 mẫu nên chỉ dùng để tham khảo định tính. Trục tung bắt đầu từ 97%; PhoBERT V2 CRF và ELECTRA chưa đối chiếu log nguồn.

thức số lượng, nhưng bảng kết quả chưa cho biết cải thiện đến từ phân biệt loại hay xác định ranh giới. Giả thuyết này cần được kiểm chứng bằng phân tích lỗi và thí nghiệm loại bỏ thành phần.

**Cải thiện cục bộ và hiệu suất trung bình theo loại.** Trung bình cộng F1 của năm loại thực thể (Macro F1) đạt khoảng 97,91% với PhoBERT V2 + CRF-H-SupCon, so với 97,94% của PhoBERT V2 + CRF. Như vậy, mức tăng trên SL chưa bù được các mức giảm ở bốn nhãn còn lại. Kết quả này cho thấy cần đánh giá đồng thời từng loại thực thể và chỉ số tổng hợp; một cải thiện riêng lẻ chưa đủ để kết luận phương pháp nâng cao chất lượng nhận diện một cách nhất quán.

**Đặc điểm nhận diện giữa các nhóm thực thể.** NG đạt F1 cao nhất trong cả năm cấu hình, từ 99,70% đến 99,99%. Xu hướng này phù hợp với giả thuyết rằng các biểu thức ngày tháng có cấu trúc tương đối quy tắc, song chưa trực tiếp chứng minh nguyên nhân. Với PhoBERT V2 + CRF-H-SupCon, các nhãn còn lại lần lượt đạt 97,69% (CQ), 97,39% (SL), 97,31% (VBPL) và 97,21% (ĐT). Khoảng cách giữa NG và ĐT cho thấy độ khó nhận diện khác nhau giữa các nhóm, nhưng F1 riêng lẻ chưa phân biệt được lỗi bỏ sót, dự đoán thừa hay sai ranh giới.

**Khác biệt giữa các backbone.** So với XLM-R + CRF-H-SupCon, PhoBERT V2 + CRF-H-SupCon cao hơn 0,64 điểm ở CQ, 1,19 điểm ở ĐT và 0,40 điểm ở SL, nhưng thấp hơn 0,10 điểm ở VBPL và 0,04 điểm ở NG. ELECTRA + CRF-H-SupCon đạt F1 cao hơn hai cấu hình này ở CQ (97,80%), ĐT (97,80%) và SL (97,40%), nhưng thấp hơn ở VBPL (96,80%) và NG (99,70%). Do đó, không có một backbone vượt trội ở mọi loại thực thể trong nhóm được đánh giá trên 10.278 mẫu. BamiBERT đạt F1 cao nhất trong hàng của mình ở NG (99,84%) và thấp nhất ở VBPL (95,50%); do sử dụng 5.162 mẫu, các trị số này chỉ mang tính mô tả, không dùng để xếp hạng trực tiếp với các hàng còn lại.

**Giới hạn diễn giải và hướng kiểm chứng.** Bảng IV mới ghi nhận tín hiệu cải thiện của H-SupCon trên SL ở đối chứng PhoBERT V2, chưa cho thấy lợi ích đồng đều giữa các loại thực thể. Các chênh lệch nhỏ chưa có khoảng tin cậy hoặc kiểm định thống kê; XLM-R, ELECTRA và BamiBERT cũng chưa có đối chứng CRF cùng backbone trong bảng. Để xác định đóng góp của H-SupCon, cần giữ cố định dữ liệu, backbone, seed và ngân sách huấn luyện, chỉ thay đổi thành phần loss, đồng thời phân tích lỗi theo loại, độ dài và ranh giới thực thể.

### C. Ablation cần thiết

Bốn cấu hình tối thiểu cần được chạy trên cùng điều kiện: (i) CRF; (ii) CRF + SupCon trùng BIO ($\alpha = 0$); (iii) CRF + H-SupCon nhưng giữ $\mathcal{O}$; và (iv) CRF + H-SupCon đầy đủ. Cần quét $\alpha$, $\lambda$ và $\tau$ chỉ trên tập phát triển; báo cáo tỷ lệ anchor hợp lệ theo nhãn, ít nhất năm seed, khoảng tin cậy và kiểm định cặp trên cùng tập kiểm thử. Thiết kế này lần lượt kiểm chứng vai trò của liên kết mềm, việc loại $\mathcal{O}$, độ ổn định và ý nghĩa thống kê của mức tăng. Ngoài ra, cần so sánh Two-Stage với Joint Optimization dưới cùng số bước cập nhật và ngân sách tính toán để tách lợi ích của loss khỏi lịch huấn luyện.

## V. Thảo luận

Theo bảng tổng hợp chưa đủ log đối chứng, CRF-H-SupCon thấp hơn CRF 0,06 điểm F1 trên PhoBERT V2; chênh lệch này cần được xác minh lại. Khác biệt giữa XLM-R, PhoBERT V2 và ELECTRA còn phản ánh ảnh hưởng backbone; BamiBERT chỉ có ý nghĩa mô tả do dùng tập kiểm thử khác kích thước. Về cơ chế, CRF ràng buộc chuyển tiếp nhãn, còn H-SupCon định hình biểu diễn token; đầu chiếu bị loại khi suy luận nên chỉ làm tăng chi phí huấn luyện.

Việc thiếu ablation $\alpha = 0$, giữ/bỏ O và nhiều seed chưa cho phép tách tác động của loss mới. PAP_NER cũng chỉ đo nhận diện trích dẫn pháp luật trong thủ tục hành chính, không đại diện cho mọi văn bản pháp lý.

## VI. Hạn chế và hướng phát triển

### A. Hạn chế

Kết quả mới dựa trên một lần chạy cho mỗi cấu hình, chưa có khoảng tin cậy hoặc kiểm định thống kê. Đối chứng CRF cùng backbone chưa đầy đủ; hai hàng PhoBERT V2 + CRF và ELECTRA còn thiếu log nguồn. BamiBERT sử dụng tập kiểm thử riêng, trong khi cách xử lý BIO chưa được xác nhận thống nhất giữa các lần đánh giá. Những giới hạn này chưa cho phép tách đóng góp của H-SupCon khỏi ảnh hưởng của backbone và cấu hình huấn luyện.

PAP_NER chỉ phản ánh miền thủ tục hành chính, nên khả năng khái quát sang các loại văn bản pháp lý khác còn chưa rõ. F1 tổng hợp chưa đủ để xác định mức cải thiện ở thực thể dài, lớp hiếm hay lỗi ranh giới. Chi phí huấn luyện của nhánh tương phản và hiệu quả trong hệ thống ứng dụng phía sau cũng chưa được đo trực tiếp.

### B. Hướng phát triển

Ưu tiên trước hết là hoàn thiện log, cấu hình và dự đoán gốc, đồng thời thống nhất tập kiểm thử và bộ đánh giá BIO. Cần bổ sung đối chứng CRF trên từng backbone, ablation về liên kết mềm và việc loại O, cùng so sánh huấn luyện hai giai đoạn với tối ưu đồng thời. Các cấu hình cần dùng cùng ngân sách cập nhật, chọn siêu tham số trên tập phát triển và chạy ít nhất năm seed để đánh giá độ ổn định và ý nghĩa thống kê.

Phân tích tiếp theo cần xét loại, độ dài và lỗi ranh giới thực thể, kết hợp theo dõi tỷ lệ anchor hợp lệ và độ tương đồng biểu diễn. Trên cơ sở đó, có thể khảo sát trọng số phân cấp thích nghi và lấy mẫu phân tầng. Đánh giá chéo miền, độ bền trước lỗi OCR, thời gian và bộ nhớ huấn luyện, cùng tác động lên truy xuất–sinh câu trả lời sẽ làm rõ phạm vi ứng dụng.

## VII. Kết luận

Bài báo trình bày CRF–H-SupCon cho nhận diện thực thể trong văn bản hành chính tiếng Việt, khai thác quan hệ giữa nhãn BIO và loại thực thể để xây dựng mục tiêu học biểu diễn phân cấp. Cơ chế trọng số phân biệt cặp trùng nhãn với cặp cùng loại khác tiền tố, kết hợp với CRF trong quá trình tối ưu đồng thời. Đầu chiếu chỉ tham gia huấn luyện nên đường suy luận vẫn gồm bộ mã hóa, tầng phát xạ và CRF.

Trên 10.278 mẫu kiểm thử PAP_NER, XLM-R và PhoBERT V2 kết hợp CRF–H-SupCon lần lượt đạt Micro F1 khớp cả biên và loại là 97,28% và 97,92%. BamiBERT đạt 98,48% trên tập riêng gồm 5.162 mẫu, chỉ có ý nghĩa mô tả. Hiệu suất thay đổi theo nhóm thực thể và backbone, chưa đủ chứng minh lợi ích độc lập của H-SupCon. Nghiên cứu cung cấp một thiết kế cụ thể cho học biểu diễn phân cấp trong NER hành chính và cơ sở để tiếp tục kiểm chứng bằng các thí nghiệm có kiểm soát.

## Tài liệu tham khảo


[1] D.-D. La, T.-B. Tran, N.-H. Du, N.-H. Dang, T.-N. Phung, and V.-K. Tran, "PAP_NER: A large-scale vietnamese administrative named entity recognition corpus and hybrid deep learning architecture," *PLOS ONE*, vol. 21, no. 7, p. e0353166, 2026. [Online]. Available: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0353166

[2] T. H. Truong, M. H. Dao, and D. Q. Nguyen, "COVID-19 named entity recognition for vietnamese," in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2021, pp. 2146–2153. [Online]. Available: https://aclanthology.org/2021.naacl-main.173/

[3] T. T. Nguyen, N. D. Nguyen, X. B. Ngo, and M. P. Tu, "Joint reference and relation extraction from legal documents with enhanced decoder input," *Cybernetics and Information Technologies*, vol. 23, no. 2, pp. 72–86, 2023. [Online]. Available: https://doi.org/10.2478/cait-2023-0014

[4] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Unsupervised cross-lingual representation learning at scale," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 8440–8451. [Online]. Available: https://aclanthology.org/2020.acl-main.747/

[5] D. Q. Nguyen and A. Tuan Nguyen, "PhoBERT: Pre-trained language models for vietnamese," in *Findings of the Association for Computational Linguistics: EMNLP 2020*. Association for Computational Linguistics, 2020, pp. 1037–1042. [Online]. Available: https://aclanthology.org/2020.findings-emnlp.92/

[6] D. Q. Nguyen, T. Pham, C. Tran, and L. T. Nguyen, "BamiBERT: A new BERT-based language model for vietnamese," 2026. [Online]. Available: https://arxiv.org/abs/2607.02259

[7] K. Clark, M.-T. Luong, Q. V. Le, and C. D. Manning, "ELECTRA: Pre-training text encoders as discriminators rather than generators," in *International Conference on Learning Representations*, 2020. [Online]. Available: https://openreview.net/forum?id=r1xMH1BtvB

[8] J. Lafferty, A. McCallum, and F. C. N. Pereira, "Conditional random fields: Probabilistic models for segmenting and labeling sequence data," in *Proceedings of the Eighteenth International Conference on Machine Learning*. Morgan Kaufmann, 2001, pp. 282–289. [Online]. Available: https://www.cs.columbia.edu/~jebara/6772/papers/crf.pdf

[9] P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, and D. Krishnan, "Supervised contrastive learning," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 18 661–18 673. [Online]. Available: https://papers.neurips.cc/paper_files/paper/2020/hash/d89a66c7c80a29b1bdbab0f2a1a94af8-Abstract.html

[10] S. S. S. Das, A. Katiyar, R. Passonneau, and R. Zhang, "CONTaiNER: Few-shot named entity recognition via contrastive learning," in *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2022, pp. 6338–6353. [Online]. Available: https://aclanthology.org/2022.acl-long.439/

[11] S. Si, S. Zeng, J. Lin, and B. Chang, "SCL-RAI: Span-based contrastive learning with retrieval augmented inference for unlabeled entity problem in NER," in *Proceedings of the 29th International Conference on Computational Linguistics*. International Committee on Computational Linguistics, 2022, pp. 2313–2318. [Online]. Available: https://aclanthology.org/2022.coling-1.202/

[12] Q. Guo, Y. Dong, L. Tian, Z. Kang, Y. Zhang, and S. Wang, "BANER: Boundary-aware LLMs for few-shot named entity recognition," in *Proceedings of the 31st International Conference on Computational Linguistics*. Association for Computational Linguistics, 2025, pp. 10 375–10 389. [Online]. Available: https://aclanthology.org/2025.coling-main.691/

[13] X. Yang, R. Zhao, and H. Li, "A contrastive and uncertainty-aware framework for multimodal named entity recognition," *Electronics*, vol. 15, no. 13, p. 2770, 2026. [Online]. Available: https://www.mdpi.com/2079-9292/15/13/2770

[14] D.-D. La, T.-B. Tran, N.-H. Du, N.-H. Dang, T.-N. Phung, and V.-K. Tran, "PAP_NER dataset," 2025. [Online]. Available: https://doi.org/10.5281/zenodo.18044019

[15] H. Nakayama, "seqeval: A python framework for sequence labeling evaluation," 2018. [Online]. Available: https://github.com/chakki-works/seqeval