Học tương phản có giám sát phân cấp ở mức token kết hợp CRF cho nhận dạng thực thể trong văn bản thủ tục hành chính tiếng Việt

Nguyễn Thị Bích Nguyên, Lê Trung Kiên, Huỳnh Tiến Đạt
Đặng Thành Tài, Nguyễn Trường Giang và Nguyễn Thành Hưng
Khoa Công nghệ Thông tin 2, Học viện Công nghệ Bưu chính Viễn thông, Việt Nam
Email tác giả liên hệ: ntbichnguyen@ptithcm.edu.vn

***Tóm tắt*—Nhận diện thực thể trong văn bản thủ tục hành chính tiếng Việt gặp hai khó khăn liên quan: thực thể dài dễ sai ranh giới và các loại ít xuất hiện cung cấp ít mẫu dương trong mỗi mini-batch. Học tương phản theo nhãn BIO chính xác còn tạo xung đột khi coi `B-X` và `I-X` của cùng loại thực thể là cặp âm. Nghiên cứu này đề xuất hàm mất mát học tương phản có giám sát phân cấp (H-SupCon): các token trùng nhãn BIO là mẫu dương mạnh, token cùng loại nhưng khác tiền tố BIO là mẫu dương mềm, còn nhãn `O` bị loại khỏi nhánh tương phản. H-SupCon được tối ưu đồng thời với log-hợp lý âm của CRF; đầu chiếu chỉ dùng khi huấn luyện nên không làm tăng đường suy luận. Trên phiên bản PAP_NER khử trùng lặp, ELECTRA + CRF + H-SupCon đạt 98,85% Strict Micro F1, cao hơn cấu hình ELECTRA + CRF tương ứng 0,41 điểm; F1 của văn bản pháp luật tăng từ 96,64% lên 97,64%. Tuy nhiên, hai lần chạy còn khác thiết lập rút gọn loss CRF, nên kết quả là bằng chứng sơ bộ chứ chưa phải phép ablation nhân quả. Bài viết vì vậy trình bày rõ công thức loss, kiến trúc hai nhánh và giao thức kiểm chứng cần thiết cho kết luận chặt chẽ hơn.**

***Từ khóa*—nhận diện thực thể, tiếng Việt, PAP_NER, CRF, học tương phản có giám sát, ranh giới thực thể.**

I. Giới thiệu

Văn bản thủ tục hành chính thường chứa tên cơ quan thực hiện, đối tượng áp dụng, thời điểm, số lượng và căn cứ pháp lý. Một hệ thống NER có thể chuyển các đoạn văn bản này thành các thực thể có ranh giới và loại xác định, phục vụ tìm kiếm, đối chiếu quy định và hỗ trợ xử lý hồ sơ. Khó khăn nổi bật là các cụm tên cơ quan hoặc trích dẫn văn bản pháp luật có thể dài, chứa ký hiệu và dễ bị tách sai ranh giới.

PAP_NER là bộ dữ liệu công khai gồm năm loại thực thể: cơ quan (CQ), đối tượng (ĐT), văn bản pháp luật (VBPL), ngày tháng (NG) và số lượng (SL) [1]. Trong tập huấn luyện địa phương, số token `I-VBPL` gấp khoảng 3,31 lần `B-VBPL`; đồng thời SL chỉ chiếm 7,15% tổng số thực thể của toàn bộ dữ liệu. Hai đặc điểm này gợi ra một khoảng trống: mục tiêu học biểu diễn cần bảo toàn quan hệ giữa phần mở đầu và phần thân của thực thể dài, nhưng vẫn phải giữ thông tin ranh giới BIO và cung cấp tín hiệu đủ mạnh cho lớp hiếm.

SupCon theo nhãn BIO chính xác kéo các token cùng `B-X` hoặc cùng `I-X` lại gần nhau, nhưng xem `B-X` và `I-X` là cặp âm dù chúng cùng loại thực thể. Ngược lại, nếu gộp hoàn toàn hai tiền tố thì biểu diễn có thể mất tín hiệu vị trí cần cho giải mã chuỗi. Khoảng trống khoa học của bài toán là thiết kế quan hệ dương có mức độ, thay vì lựa chọn nhị phân "trùng nhãn" hoặc "trùng loại".

Nghiên cứu này có ba đóng góp chính:

- **Thứ nhất:** Đề xuất ma trận tương đồng phân cấp, trong đó cặp trùng BIO có trọng số 1 và cặp cùng loại khác tiền tố có trọng số α, đồng thời loại nhãn `O` khỏi loss tương phản.
- **Thứ hai:** Kết hợp đồng thời H-SupCon với CRF để tối ưu cả hình học biểu diễn token và tính hợp lệ toàn cục của chuỗi nhãn; nhánh tương phản được tách khỏi suy luận.
- **Thứ ba:** Phân tích tín hiệu thực nghiệm theo từng loại thực thể và xác định các ablation còn thiếu để phân biệt lợi ích của H-SupCon với thay đổi cấu hình khác.

Kết quả trên dữ liệu gốc và dữ liệu khử trùng lặp được trình bày riêng vì hai phiên bản sử dụng các tập kiểm thử khác nhau.

II. Công trình liên quan

PAP_NER do La và cộng sự công bố là bộ dữ liệu nhận diện thực thể cho văn bản thủ tục hành chính tiếng Việt, gồm 162.801 câu và 205.807 thực thể thuộc năm loại: cơ quan, đối tượng, văn bản pháp luật, ngày tháng và số lượng [1]. Công trình này đã đánh giá BiLSTM+CRF, ELECTRA, XLM-R, PhoBERT và PhoBERT+CRF; trong đó PhoBERT+CRF đạt 97,95% Micro F1 trên tập kiểm thử của tác giả [1]. Đây là cơ sở đối chiếu trực tiếp cho nghiên cứu của chúng tôi.

Các bộ dữ liệu NER tiếng Việt trước đó chủ yếu tập trung vào những miền và loại thực thể khác. Chẳng hạn, PhoNER_COVID19 được xây dựng cho thông tin y tế liên quan đến COVID-19 [2]. Trong miền pháp luật Việt Nam, Nguyen và cộng sự nghiên cứu việc trích xuất tham chiếu và quan hệ giữa các tham chiếu trong văn bản pháp luật [3]. Những công trình này cho thấy nhu cầu xử lý thực thể và cấu trúc thông tin đặc thù theo miền, song khác PAP_NER về tác vụ, hệ thống nhãn hoặc dữ liệu đánh giá.

Về kiến trúc, XLM-R là mô hình tiền huấn luyện đa ngôn ngữ [4], trong khi PhoBERT và BamiBERT được phát triển cho tiếng Việt [5], [6]; ELECTRA sử dụng mục tiêu phân biệt token bị thay thế khi tiền huấn luyện [7]. Đối với gán

nhãn chuỗi, CRF mô hình hóa sự phụ thuộc giữa các nhãn liên tiếp [8]. Học tương phản có giám sát tổ chức không gian biểu diễn bằng quan hệ dương và âm [9]. CONTaiNER học khoảng cách giữa token trong NER ít mẫu [10], còn SCL-RAI đối chiếu biểu diễn ở mức span [11]. BANER cho thấy loss nhận biết ranh giới là một hướng riêng quan trọng [12]. Tuy vậy, các công trình này không giải quyết trực tiếp quan hệ phân cấp giữa `B-X` và `I-X` trong NER thủ tục hành chính đầy đủ dữ liệu, cũng chưa kết hợp quan hệ dương mềm này với CRF trong một mục tiêu chung.

III. Dữ liệu và phương pháp

A. Bộ dữ liệu

Ngữ liệu sử dụng trong nghiên cứu gồm các câu thuộc mô tả thủ tục hành chính được công bố trên Cổng Dịch vụ công Quốc gia và các cơ sở dữ liệu hành chính cấp tỉnh [1], [13]. Nội dung bao gồm tên cơ quan giải quyết, đối tượng thực hiện thủ tục, căn cứ pháp lý, thời hạn xử lý và các khoản phí hoặc số lượng liên quan. Văn bản đã được tách từ; những tiếng tạo thành một từ được nối bằng dấu gạch dưới, chẳng hạn `làm_việc`.

Mỗi câu được lưu thành một dãy token, mỗi token nằm trên một dòng. Trong các tệp sử dụng ở nghiên cứu này, một dòng gồm năm cột: token, nhãn từ loại, nhãn cụm từ, nhãn thực thể và một cột phụ. Các câu được ngăn cách bằng dòng trống. Bài toán nhận diện thực thể sử dụng chuỗi token làm đầu vào và nhãn thực thể làm đầu ra. Ví dụ, một đoạn trong dữ liệu có dạng:

```
05          M   I-NP   B-NG   O
ngày        N   I-NP   I-NG   O
làm_việc    V   B-VP   O      O
```

Nhãn thực thể tuân theo quy ước BIO: `B-X` đánh dấu token đầu tiên của một thực thể loại `X`, `I-X` đánh dấu các token tiếp theo trong cùng thực thể và `O` biểu thị token không thuộc thực thể nào. Có năm loại thực thể: CQ (cơ quan), ĐT (đối tượng), VBPL (văn bản pháp luật), NG (ngày hoặc khoảng thời gian) và SL (số lượng). Như vậy, bài toán sử dụng 11 nhãn ở mức token, gồm `O` và hai nhãn `B`/`I` cho mỗi loại thực thể.

Ba tập gốc gồm 142.218 câu huấn luyện, 10.305 câu phát triển và 10.278 câu kiểm thử; tổng cộng 162.801 câu, 3.711.201 token sau tách từ và 205.807 lượt xuất hiện thực thể. Để khảo sát ảnh hưởng của các câu lặp, nghiên cứu còn sử dụng một phiên bản được tạo bằng cách gộp ba tập, loại các câu trùng theo chuỗi token rồi chia lại thành 24.089 câu huấn luyện, 5.162 câu phát triển và 5.162 câu kiểm thử. Phiên bản này có 34.413 câu, 783.777 token và 42.489 lượt xuất hiện thực thể. Bảng I trình bày số thực thể của từng loại.

Hai phiên bản sử dụng các tập kiểm thử khác nhau. Vì vậy, chênh lệch điểm giữa chúng phản ánh đồng thời thay đổi về dữ liệu huấn luyện và dữ liệu đánh giá, không thể quy riêng cho thao tác khử trùng lặp.

B. Mô hình và cấu hình thực nghiệm

Nghiên cứu khảo sát XLM-R Base (∼270 triệu tham số), PhoBERT Base V2 (∼135 triệu), ELECTRA tiếng Việt (∼110–134 triệu) và BamiBERT (∼103 triệu). XLM-R là mô hình đa ngôn ngữ; ba nhóm còn lại hướng tới tiếng Việt [4], [5], [7], [6]. Các con số chỉ mô tả mô hình nền, chưa gồm tầng phân loại, CRF và đầu chiếu tương phản.

Bảng I
Phân bố thực thể trong hai phiên bản dữ liệu.

Loại thực thể	Dữ liệu gốc	Khử trùng lặp
CQ (cơ quan)	62.915	13.939
ĐT (đối tượng)	67.001	15.218
VBPL (văn bản pháp luật)	25.522	3.968
NG (ngày, thời gian)	35.647	8.029
SL (số lượng)	14.722	1.335
Tổng	**205.807**	**42.489**

Bảng II
Các cấu hình thực nghiệm được khảo sát.

Mã	Thành phần	Dữ liệu
V1	Encoder + CRF	Gốc
V2	Encoder + Softmax	Gốc
V3	Encoder + CRF	Khử lặp (70/15/15)
V4	**Encoder + CRF + H-SupCon** (λ=0,3)	**Khử lặp** (70/15/15)
BS	Encoder + Softmax	Khử lặp (70/15/15)

Mỗi mô hình nền được khảo sát với các cách giải mã và chế độ dữ liệu trong Bảng II. V1 và V2 sử dụng cách chia dữ liệu gốc; V3 và V4 sử dụng cách chia lại sau khử trùng lặp. Hai tập kiểm thử này khác nhau, vì vậy việc so sánh trực tiếp điểm giữa hai chế độ dữ liệu cần được diễn giải thận trọng.

Đối với ELECTRA, các cấu hình V1, V3 và V4 sử dụng checkpoint `NlpHUST/electra-base-vn`, còn V2 sử dụng `FPTAI/velectra-base-discriminator-cased`. Do đó, so sánh V1 với V2 của mô hình này đồng thời chịu ảnh hưởng của việc thay đổi checkpoint và tầng giải mã. Các bảng kết quả tiếp theo chỉ ghi điểm kiểm thử của những cấu hình có báo cáo tương ứng; điểm trên tập phát triển được trình bày riêng.

C. Hàm mất mát CRF–H-SupCon

Với biểu diễn theo từ $\mathbf{h}_i \in \mathbb{R}^d$, đầu chiếu hai tầng tạo $\mathbf{z}_i = g(\mathbf{h}_i)/\|g(\mathbf{h}_i)\|_2$. Đầu phân loại tạo điểm phát xạ cho CRF; CRF tối thiểu hóa log-hợp lý âm $\mathcal{L}_{\mathrm{CRF}}$ và dùng Viterbi khi suy luận [8]. Nhánh tương phản chỉ xét tập token thực thể $\mathcal{I}_e = \{i \mid y_i \neq \mathtt{O}\}$.

Gọi $t(y)$ là loại thực thể sau khi bỏ tiền tố BIO. Với $i \neq j$, trọng số dương phân cấp được định nghĩa:

$$w_{ij} = \begin{cases} 1, & y_i = y_j, \\ \alpha, & t(y_i) = t(y_j),\ y_i \neq y_j, \\ 0, & \text{ngược lại}, \end{cases} \qquad 0 < \alpha < 1. \quad (1)$$

Cặp trùng BIO là mẫu dương mạnh; cặp `B-X`/`I-X` cùng loại là mẫu dương mềm. Cách này duy trì liên kết ngữ nghĩa trong thực thể dài nhưng không đồng nhất hoàn toàn vai trò ranh

giới. Với $\mathcal{A}(i) = \mathcal{I}_e \setminus \{i\}$ và $s_{ik} = \mathbf{z}_i^\top \mathbf{z}_k/\tau$, loss cho anchor hợp lệ là:

$$\ell_i = -\frac{1}{\sum_{j\in\mathcal{A}(i)} w_{ij}} \sum_{j\in\mathcal{A}(i)} w_{ij} \log \frac{e^{s_{ij}}}{\sum_{k\in\mathcal{A}(i)} e^{s_{ik}}}. \quad (2)$$

Chỉ các anchor có $\sum_j w_{ij} > 0$ được lấy trung bình để tránh chia cho 0. Mục tiêu cuối cùng là

$$\mathcal{L} = \mathcal{L}_{\text{CRF}} + \lambda \mathcal{L}_{\text{H-SupCon}}, \quad \lambda = 0{,}3,\ \alpha = 0{,}3,\ \tau = 0{,}07. \quad (3)$$

Loại `O` vẫn tham gia đầy đủ vào CRF nhưng không chi phối mẫu âm của H-SupCon. Khi kiểm thử, đầu chiếu và loss tương phản được bỏ; đường suy luận chỉ còn encoder, tầng phát xạ và Viterbi.

Hình 1 thể hiện hai tín hiệu bổ trợ: CRF học phụ thuộc chuyển tiếp của toàn chuỗi, còn H-SupCon tổ chức hình học biểu diễn ở mức token. Tối ưu đồng thời cho phép cả hai gradient cập nhật encoder trong cùng một bước, tránh việc không gian tương phản bị thay đổi ở một giai đoạn huấn luyện CRF tách biệt.

D. Phép đánh giá

Một thực thể chỉ được tính đúng khi cả ranh giới và loại đều khớp nhãn chuẩn. Chỉ số chính là Strict Micro F1, tính từ tổng TP, FP và FN của năm loại thực thể:

$$P_{\text{micro}} = \frac{\sum_c TP_c}{\sum_c (TP_c + FP_c)}, \quad (4)$$

$$R_{\text{micro}} = \frac{\sum_c TP_c}{\sum_c (TP_c + FN_c)}, \quad (5)$$

$$F_{1,\text{micro}} = \frac{2P_{\text{micro}}R_{\text{micro}}}{P_{\text{micro}} + R_{\text{micro}}}. \quad (6)$$

Các chỉ số theo loại và Macro F1 được báo cáo để tránh việc lớp lớn chi phối diễn giải. Điểm được tính theo chuẩn BIO bằng `seqeval` với `mode='strict'` và `scheme=IOB2` [14].

Để tách lỗi ranh giới khỏi lỗi phân loại, bốn chế độ đối sánh được dùng:

- **Strict:** đúng cả ranh giới và loại thực thể;
- **Exact:** đúng ranh giới, không xét loại thực thể;
- **Partial:** ranh giới có giao nhau, không xét loại;
- **Type:** ranh giới có giao nhau và đúng loại.

Exact giúp nhận diện lỗi phân loại khi ranh giới đã đúng; Partial và Type cho biết mô hình có định vị đúng vùng thực thể hay không. Điểm kiểm soát được chọn theo F1 thực thể trên tập phát triển; các bảng kết quả được tính trên tập kiểm thử tương ứng.

IV. Kết quả

A. So sánh tổng quan

Trong các phiên bản chính V1–V4 có kết quả kiểm thử kiểm chứng được, ELECTRA V4 đạt F1 cao nhất (98,85%). Khi xét cả thí nghiệm Softmax khử trùng lặp bổ sung, PhoBERT V2 đạt 98,91%, hơn ELECTRA V4 khoảng 0,06 điểm phần trăm. Chênh lệch này nhỏ và mỗi cấu hình hiện chỉ có một lần chạy được báo cáo; vì vậy không đủ cơ sở khẳng định cấu hình PhoBERT vượt trội ổn định. XLM-R V3 có điểm phát triển tốt nhất 98,88% nhưng thiếu chỉ số kiểm thử, nên không đưa vào xếp hạng kiểm thử trên dữ liệu khử trùng lặp.

Trên cùng chế độ khử trùng lặp với CRF (V3), thứ tự kiểm thử của ba mô hình đã có tệp kết quả là PhoBERT V2 (98,72%), BamiBERT (98,58%) và ELECTRA (98,44%). Trên chế độ gốc, V1 của PhoBERT V2 đạt 98,04%, cao hơn XLM-R, ELECTRA và BamiBERT ở V1. Những quan sát này là so sánh **giữa các lần chạy**, chưa điều chỉnh khác biệt về điểm kiểm soát hoặc cấu hình tối ưu hóa.

B. Tín hiệu thực nghiệm của H-SupCon

So sánh gần nhất cho loss mới là ELECTRA V3 và V4: cùng mô hình nền và cùng phiên bản dữ liệu khử trùng lặp, V4 đạt 98,85% so với 98,44% của V3, tăng 0,41 điểm Strict Micro F1. Theo từng loại, mức thay đổi lần lượt là $+0{,}48$ (CQ), $+0{,}41$ (ĐT), $+1{,}00$ (VBPL), $-0{,}08$ (NG) và $+0{,}73$ điểm (SL). Mức tăng lớn nhất xuất hiện ở VBPL và SL, phù hợp với động lực thiết kế về thực thể dài và lớp ít mẫu; đây là quan sát mô tả, chưa phải bằng chứng cơ chế.

V3 và V4 đồng thời khác thiết lập `crf_reduction`, nên chênh lệch 0,41 điểm gắn với **toàn bộ thay đổi cấu hình**, chưa thể quy riêng cho H-SupCon. Các so sánh Softmax–CRF cũng không nhất quán giữa mô hình nền và chế độ dữ liệu. Kết luận nhân quả cần giữ nguyên encoder, split, seed, batch và CRF reduction, sau đó chỉ thay các thành phần của loss ở Phương trình (1)–(3).

C. Phân tích theo loại thực thể

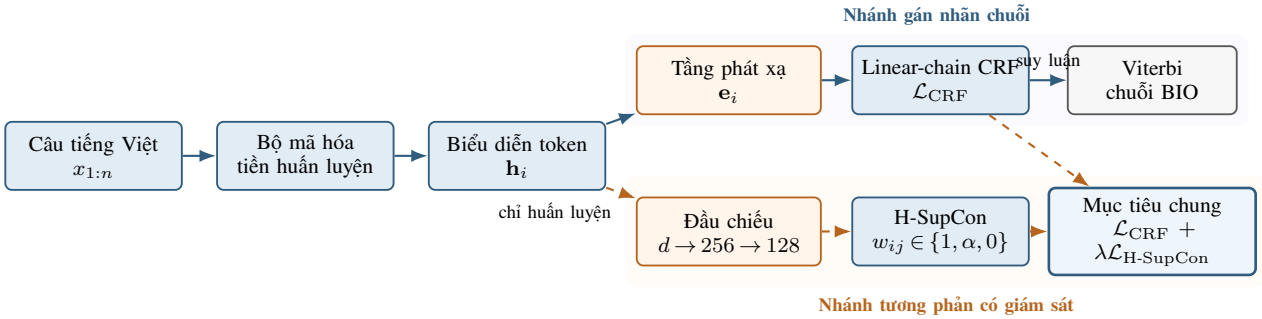
VBPL có F1 thấp hơn nhiều nhãn còn lại ở các lần chạy này và là nhãn cần chú ý trong ứng dụng pháp lý. ELECTRA V4 có F1 VBPL 97,64%, cao hơn ELECTRA V3 đúng 1,00 điểm phần trăm và cao hơn PhoBERT V2 + Softmax 1,00 điểm. Trong khi đó, PhoBERT V2 + Softmax có F1 tổng cao hơn ELECTRA V4 một chút. Điều này cho thấy xếp hạng theo F1 tổng có thể khác lựa chọn tối ưu khi ưu tiên nhận diện trích dẫn văn bản pháp luật. Bảng hiện chưa có khoảng tin cậy cho các chênh lệch theo nhãn.

D. Ablation cần thiết

Bốn cấu hình tối thiểu cần được chạy trên cùng điều kiện: (i) CRF; (ii) CRF + SupCon trùng BIO ($\alpha = 0$); (iii) CRF + H-SupCon nhưng giữ `O`; và (iv) CRF + H-SupCon đầy đủ. Cần quét α, λ và τ chỉ trên tập phát triển; báo cáo tỷ lệ anchor hợp lệ theo nhãn, ít nhất ba seed, khoảng tin cậy và kiểm định cặp trên cùng tập kiểm thử. Thiết kế này lần lượt kiểm chứng vai trò của liên kết mềm, việc loại `O`, độ ổn định và ý nghĩa thống kê của mức tăng.

V. Thảo luận

Kết quả sơ bộ ủng hộ giả thuyết rằng quan hệ dương mềm giữa `B-X` và `I-X` hữu ích hơn cho VBPL và SL so với việc chỉ tối ưu cấu trúc chuỗi. CRF và H-SupCon đóng hai vai trò khác nhau: CRF ràng buộc chuyển tiếp nhãn, còn H-SupCon thay đổi hình học biểu diễn. Đầu chiếu bị loại khi suy luận nên loss mới không thêm phép tính vào đường giải mã; chi phí huấn luyện và độ trễ thực tế vẫn cần đo thống nhất.



Hình 1. Kiến trúc huấn luyện chung CRF–H-SupCon. Đường màu xanh biểu diễn luồng suy luận; đường màu cam nét đứt biểu diễn các kết nối chỉ dùng khi huấn luyện.

Bảng III
STRICT MICRO F1 TRÊN TẬP KIỂM THỬ (%). DẤU "—" BIỂU THỊ KẾT QUẢ CHƯA ĐƯỢC BÁO CÁO.

	Dữ liệu gốc		Dữ liệu khử trùng lặp		
Mô hình nền	**CRF (V1)**	**Softmax (V2)**	**CRF (V3)**	**CRF + H-SupCon (V4)**	**Softmax (BS)**
XLM-R	97,69	97,97	—	—	—
PhoBERT V2	98,04	97,82	98,72	—	**98,91**
ELECTRA	97,70	97,24	98,44	**98,85**	—
BamiBERT	97,54	97,43	98,58	—	98,67

Bảng IV
F1 THEO LOẠI THỰC THỂ TRÊN TẬP KIỂM THỬ KHỬ TRÙNG LẶP (%).

Cấu hình	**CQ**	**ĐT**	**VBPL**	**NG**	**SL**
PhoBERT V2 + Softmax	99,20	98,63	96,64	99,92	99,75
PhoBERT V2 + CRF (V3)	98,93	98,50	96,49	99,88	98,51
ELECTRA + CRF (V3)	98,64	97,96	96,64	99,92	98,27
ELECTRA + CRF + H-SupCon (V4)	**99,12**	**98,37**	**97,64**	**99,84**	**99,00**
Thay đổi V4–V3	*+0,48*	*+0,41*	*+1,00*	$-0,08$	*+0,73*
BamiBERT + Softmax	99,22	98,15	95,89	99,96	99,25
BamiBERT + CRF (V3)	99,00	98,20	95,73	99,96	98,51

So sánh dữ liệu gốc với dữ liệu khử trùng lặp phản ánh đồng thời thay đổi tập huấn luyện và tập kiểm thử, nên điểm cao hơn không chứng minh lợi ích của khử trùng lặp. Tương tự, thiếu ablation $\alpha = 0$, giữ/bỏ nhãn O và nhiều seed khiến chưa thể tách tác động của từng thành phần trong H-SupCon. Đây là khoảng trống thực nghiệm quan trọng nhất còn lại.

Kiểm toán sơ bộ trên **bản sao dữ liệu địa phương** phát hiện 3.303 chuỗi câu chung duy nhất giữa tập phát triển và tập kiểm thử; 5.285/10.278 câu kiểm thử thuộc những chuỗi này. Chưa xác minh bản địa phương trùng từng byte với bản Zenodo, nên phát hiện này chưa được dùng để quy kết chất lượng bộ dữ liệu phát hành. Tuy nhiên, khi công bố bài báo cần đối chiếu nguồn gốc dữ liệu, vì chồng lặp giữa tập phát triển và tập kiểm thử có thể ảnh hưởng diễn giải kết quả chọn điểm kiểm soát. Quy trình tạo bản khử trùng lặp hiện chia lại từng câu sau khi gộp ba tập, khác với cách chia theo nhóm mã thủ tục mà bài PAP_NER gốc mô tả [1].

Cuối cùng, PAP_NER bắt nguồn từ thủ tục hành chính. Kết quả về VBPL trong bài đo chất lượng nhận diện **trích dẫn văn bản pháp luật bên trong thủ tục hành chính**, không chứng minh hiệu quả trên toàn bộ văn bản quy phạm pháp luật, bản án hay hợp đồng. Phạm vi này được giữ nhất quán trong tên bài, tóm tắt và kết luận.

VI. KẾT LUẬN

Bài viết đề xuất H-SupCon để mô hình hóa quan hệ phân cấp giữa nhãn BIO và loại thực thể, đồng thời tối ưu cùng CRF trong một mục tiêu thống nhất. ELECTRA V4 đạt 98,85% Strict Micro F1 và 97,64% F1 cho VBPL; so với ELECTRA V3, các mức tăng tương ứng là 0,41 và 1,00 điểm. Kết quả cho thấy tiềm năng của loss mới nhưng chưa cô lập được tác động của nó. Đóng góp chính là công thức hóa quan hệ dương mềm, kiến trúc huấn luyện hai nhánh không tăng đường suy luận, và một giao thức ablation đủ chặt để kiểm chứng giả thuyết về ranh giới dài và lớp hiếm.

TÀI LIỆU THAM KHẢO

[1] D.-D. La, T.-B. Tran, N.-H. Du, N.-H. Dang, T.-N. Phung, and V.-K. Tran, "PAP_NER: A large-scale vietnamese administrative named entity recognition corpus and hybrid deep learning architecture," *PLOS ONE*, vol. 21, no. 7, p. e0353166, 2026. [Online]. Available: https://journals.plos.org/plosone/article?id=10.1371/journal.pone.0353166

[2] T. H. Truong, M. H. Dao, and D. Q. Nguyen, "COVID-19 named entity recognition for vietnamese," in *Proceedings of the 2021 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies*. Association for Computational Linguistics, 2021, pp. 2146–2153. [Online]. Available: https://aclanthology.org/2021.naacl-main.173/

[3] T. T. T. Nguyen, N. D. Nguyen, X. B. Ngo, and M. P. Tu, "Joint reference and relation extraction from legal documents with enhanced decoder input," *Cybernetics and Information Technologies*, vol. 23, no. 2, pp. 72–86, 2023. [Online]. Available: https://doi.org/10.2478/cait-2023-0014

[4] A. Conneau, K. Khandelwal, N. Goyal, V. Chaudhary, G. Wenzek, F. Guzmán, E. Grave, M. Ott, L. Zettlemoyer, and V. Stoyanov, "Unsupervised cross-lingual representation learning at scale," in *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics*. Association for Computational Linguistics, 2020, pp. 8440–8451. [Online]. Available: https://aclanthology.org/2020.acl-main.747/

[5] D. Q. Nguyen and A. Tuan Nguyen, "PhoBERT: Pre-trained language models for vietnamese," in *Findings of the Association for Computational Linguistics: EMNLP 2020*. Association for Computational Linguistics, 2020, pp. 1037–1042. [Online]. Available: https://aclanthology.org/2020.findings-emnlp.92/

[6] D. Q. Nguyen, T. Pham, C. Tran, and L. T. Nguyen, "BamiBERT: A new BERT-based language model for vietnamese," 2026. [Online]. Available: https://arxiv.org/abs/2607.02259

[7] K. Clark, M.-T. Luong, Q. V. Le, and C. D. Manning, "ELECTRA: Pre-training text encoders as discriminators rather than generators," in *International Conference on Learning Representations*, 2020. [Online]. Available: https://openreview.net/forum?id=r1xMH1BtvB

[8] J. Lafferty, A. McCallum, and F. C. N. Pereira, "Conditional random fields: Probabilistic models for segmenting and labeling sequence data," in *Proceedings of the Eighteenth International Conference on Machine Learning*. Morgan Kaufmann, 2001, pp. 282–289. [Online]. Available: https://www.cs.columbia.edu/~jebara/6772/papers/crf.pdf

[9] P. Khosla, P. Teterwak, C. Wang, A. Sarna, Y. Tian, P. Isola, A. Maschinot, C. Liu, and D. Krishnan, "Supervised contrastive learning," in *Advances in Neural Information Processing Systems*, vol. 33, 2020, pp. 18 661–18 673. [Online]. Available: https://papers.neurips.cc/paper_files/paper/2020/hash/d89a66c7c80a29b1bdbab0f2a1a94af8-Abstract.html

[10] S. S. S. Das, A. Katiyar, R. Passonneau, and R. Zhang, "CONTaiNER: Few-shot named entity recognition via contrastive learning," in *Proceedings of the 60th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*. Association for Computational Linguistics, 2022, pp. 6338–6353. [Online]. Available: https://aclanthology.org/2022.acl-long.439/

[11] S. Si, S. Zeng, J. Lin, and B. Chang, "SCL-RAI: Span-based contrastive learning with retrieval augmented inference for unlabeled entity problem in NER," in *Proceedings of the 29th International Conference on Computational Linguistics*. International Committee on Computational Linguistics, 2022, pp. 2313–2318. [Online]. Available: https://aclanthology.org/2022.coling-1.202/

[12] Q. Guo, Y. Dong, L. Tian, Z. Kang, Y. Zhang, and S. Wang, "BANER: Boundary-aware LLMs for few-shot named entity recognition," in *Proceedings of the 31st International Conference on Computational Linguistics*. Association for Computational Linguistics, 2025, pp. 10 375–10 389. [Online]. Available: https://aclanthology.org/2025.coling-main.691/

[13] D.-D. La, T.-B. Tran, N.-H. Du, N.-H. Dang, T.-N. Phung, and V.-K. Tran, "PAP_NER dataset," 2025. [Online]. Available: https://doi.org/10.5281/zenodo.18044019

[14] H. Nakayama, "seqeval: A python framework for sequence labeling evaluation," 2018. [Online]. Available: https://github.com/chakki-works/seqeval